ESTRUTURA DE DADOS II

CURSO DE ENGENHARIA DA COMPUTAÇÃO

AULA DE HOJE

HASHING

What is Hashing?

Pesquisa

- Procedimento
- Elementos pesquisados sucessivamente
- Comparação determina se o elemento foi encontrado ou não
- Exemplo: buscar 4 (Arrays e lista encadeada)
- Importância no número médio de comparações

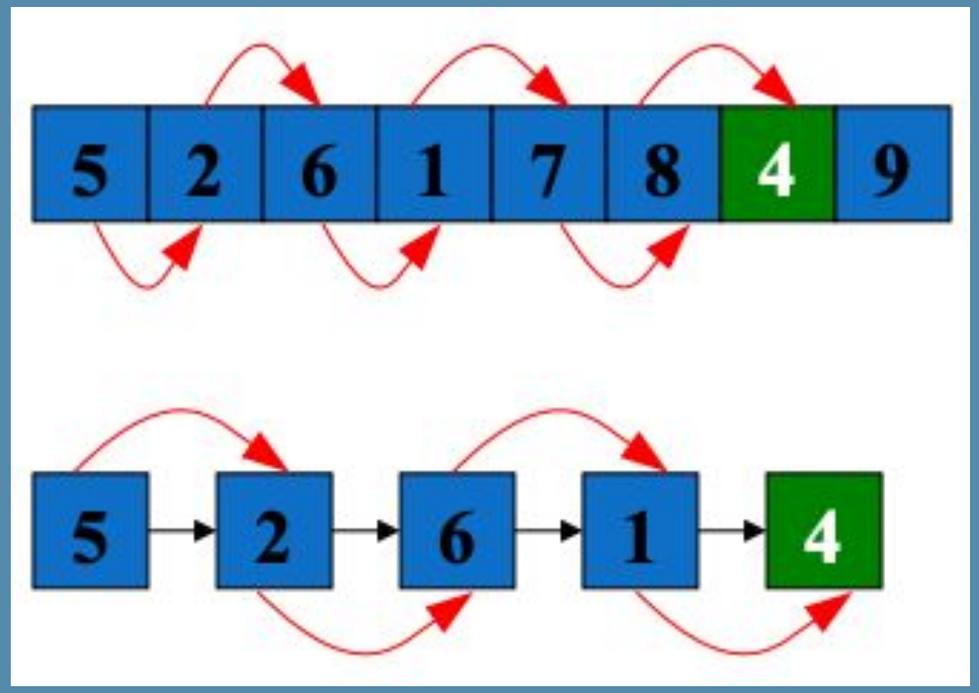

Pesquisa sequencial

- Número médio de comparações

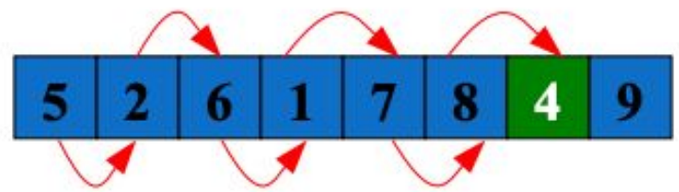

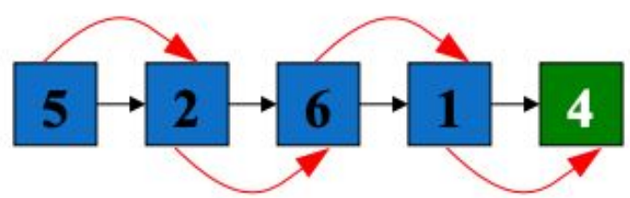

Tempo de busca:
O(n)
Comparações: (n + 1) / 2

$$\text{Comparações} = \frac{1 + 2 + 3 + \ldots. n}{n} = \frac{n\,((n+1)/2)}{n} = \frac{n + 1}{2}$$

Busca Sequencial

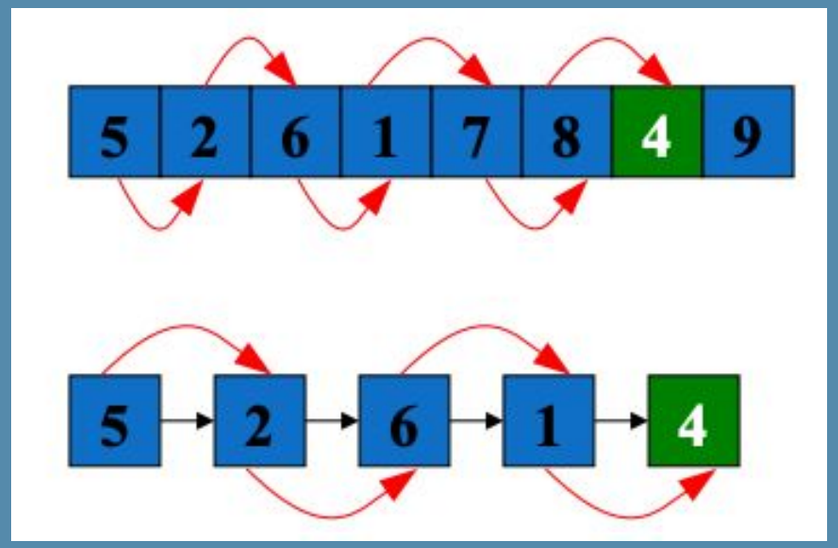

- Pesquisa sequencial em vetor não ordenado
- Necessário pesquisar em todo o vetor
- **for** i = 1 **to** tamanho_vetor {
  if vetor[i] == chave **then**
  return chave
  }

Tempo de busca:
O(n)
Comparações: (n + 1) / 2

Podemos melhorar

- Pesquisa sequencial em vetor ordenado

- **for** i = 1 **to** tamanho_vetor {
    if vetor[i] > chave **then**
        return -1
    else if vetor[i] == chave **then**
        return chave
  }

Busca sequencial usando frequência

- E se alguns valores foram mais acessados que outros?

- Neste caso, podemos ordenar pela frequência de recuperação que uma chave possui. Ou seja, a cada busca de uma chave, aumentamos sua frequência e ordenamos pela frequência...

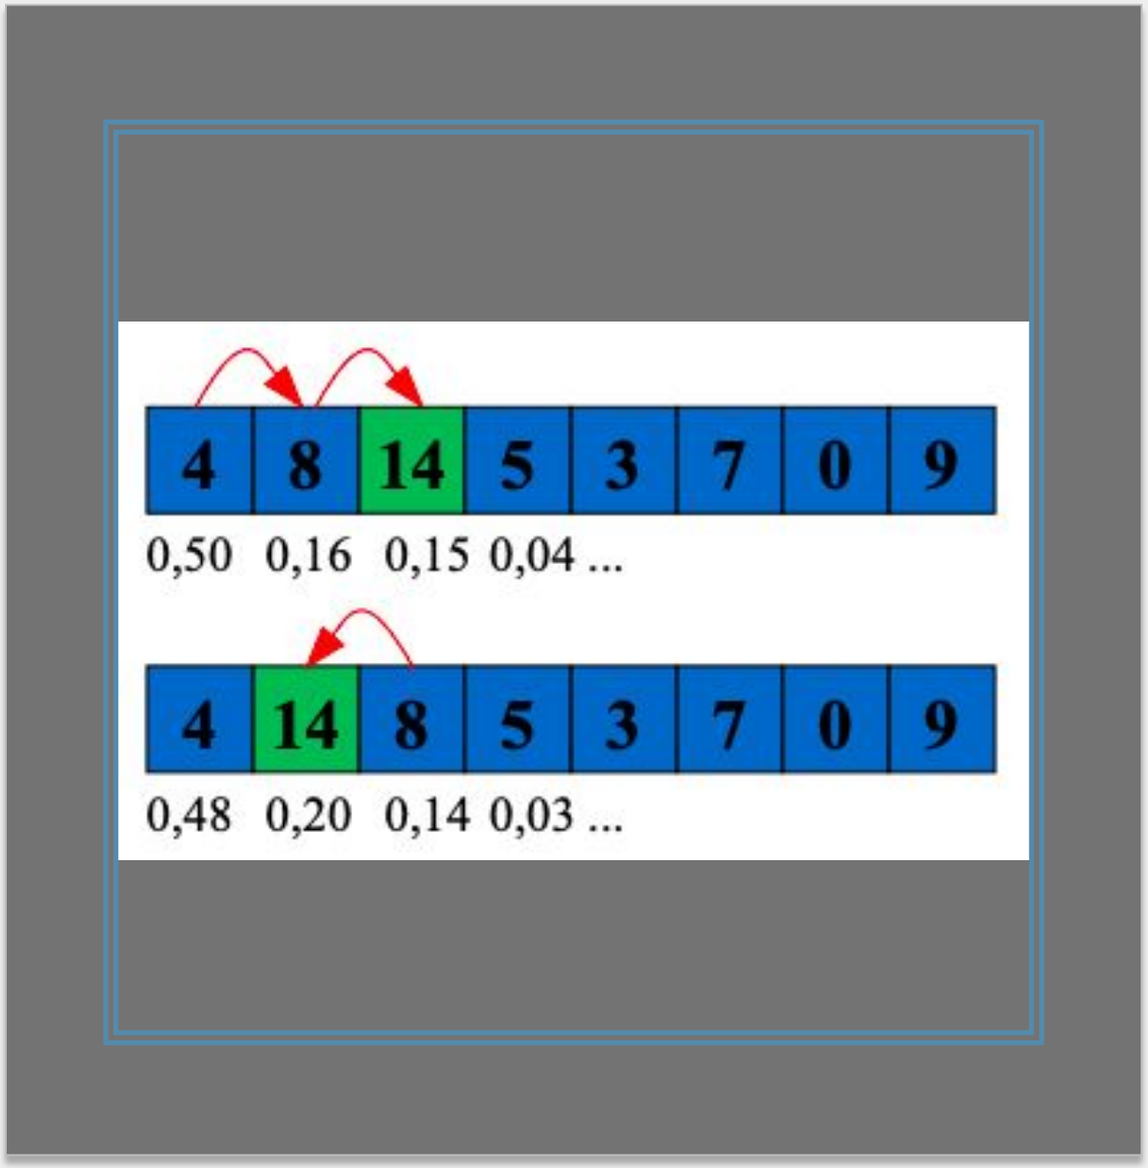

Número de Comparações: O(n)

Busca sequencial usando frequência

- Necessidade de conhecer previamente a frequência ou calculá-la utilizando um histórico de buscas bem-sucedidas
- Auto-organização (numa abordagem mais simples):
  - Armazenar o número de buscas, ao invés da frequência
  - Alterar a posição das chaves dado o número de acessos em cada chave

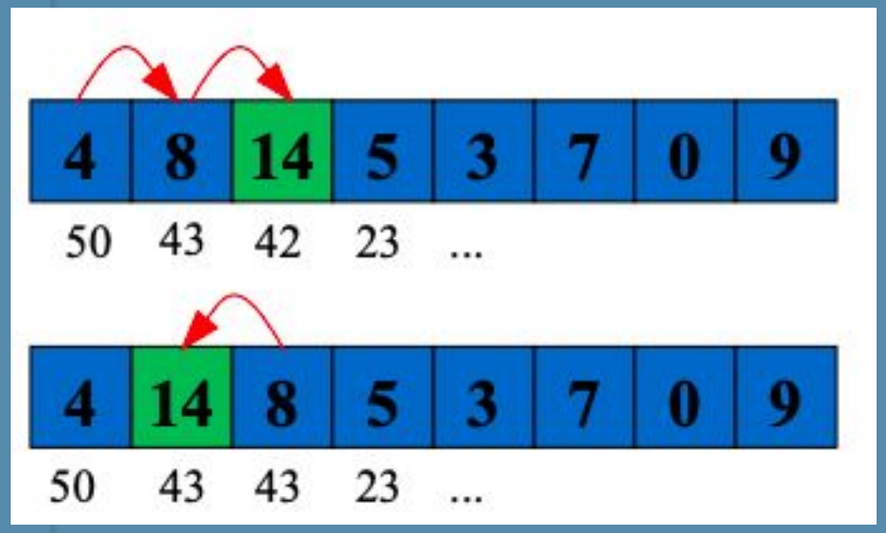

Busca Binária

- Pesquisa sequencial em vetor ordenado

```
int inf = 0, sup = Tam-1, meio;
while (inf <= sup) {
        meio = (inf + sup)/2;
        if (chave == vet[meio]) then
            return meio;
        if (chave < vet[meio]) then
            sup = meio-1;
        else
            inf = meio+1;
}
return -1;
```

Número de Comparações:

O(log n)

Abordagem diferente

- Calcular a posição da chave na tabela baseado no valor da chave

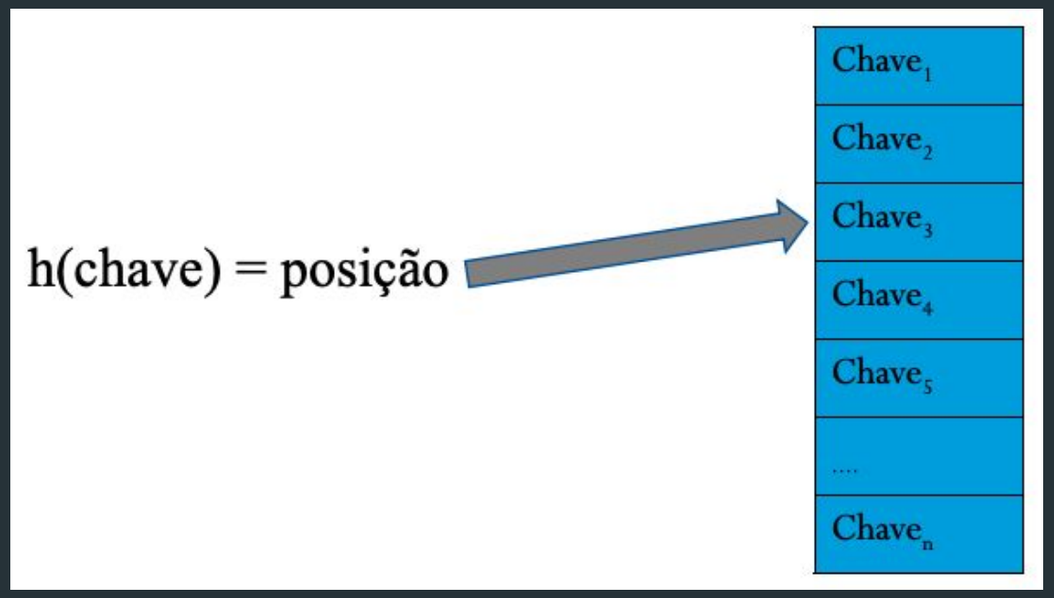

- Posição na tabela pode ser acessada diretamente
- Não há necessidade de testes
- Complexidade é reduzida para O(1)
- Busca sequencial: complexidade é O(n)
- Busca binária: complexidade é O(log n)

Hashing

- Segundo o Webster's New World Dictionary, significa:
  - Fazer picadinho de carne e vegetais para cozinhar;
  - Fazer uma bagunça
- Qualquer que seja a função de transformação, colisões irão acontecer
- O Paradoxo do aniversário (Feller, 1968, p.33) diz que em um grupo de 23 pessoas juntas ao acaso, existe uma chance maior do que 50% de que 2 pessoas comemorem aniversário no mesmo dia.
- Assim, se for utilizada uma função de transformação uniforme que enderece 23 chaves randômicas em uma tabela de tamanho 365, a probabilidade de que haja colisões é maior do que 50%

$$p = \frac{M-1}{M} \times \frac{M-2}{M} \times \ldots \times \frac{M-N+1}{M} =$$

$$\prod_{i=1}^{N} \frac{M-i+1}{M} = \frac{M!}{(M-N)!M^N}$$

Paradoxo do aniversário

- A probabilidade p de se inserir N itens consecutivos sem colisão em uma tabela de tamanho M é:

Hashing

- Alguns valores de p para diferentes valores de N, onde M=365.

N	p
10	0,883
22	0,524
23	0,493
30	0,303

Hashing

- A função h deve ser tal que
- Transforma uma chave em um índice na tabela
- Chave pode ser: cadeia de caracteres, um número, um registro …
- Função h é chamada de função hashing ou de escrutínio.
- Universo de chaves mapeado em posições

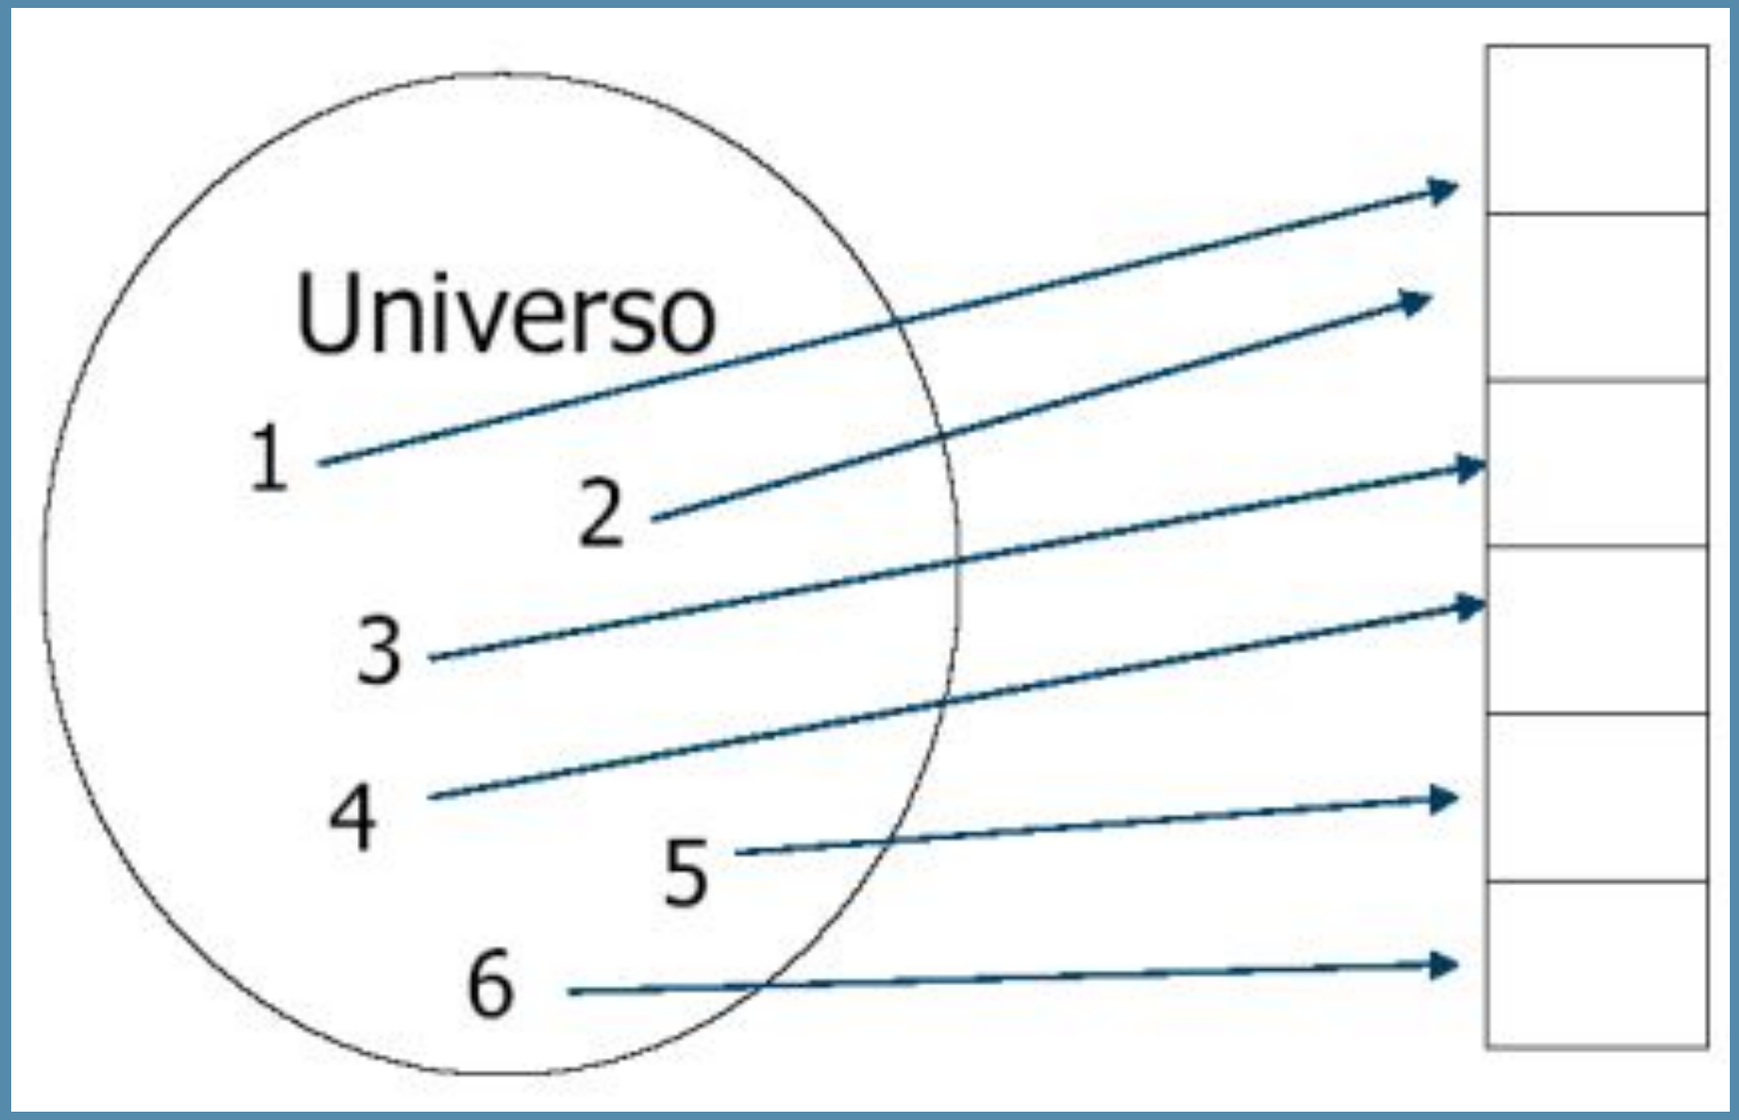

Hashing

- A função h deve ser tal que
- Transforma uma chave em um índice na tabela
- Chave pode ser: cadeia de caracteres, um número, um registro …
- Função h é chamada de função hashing ou de escrutínio.
- Universo de chaves mapeado em posições
- Colisões podem ocorrer:

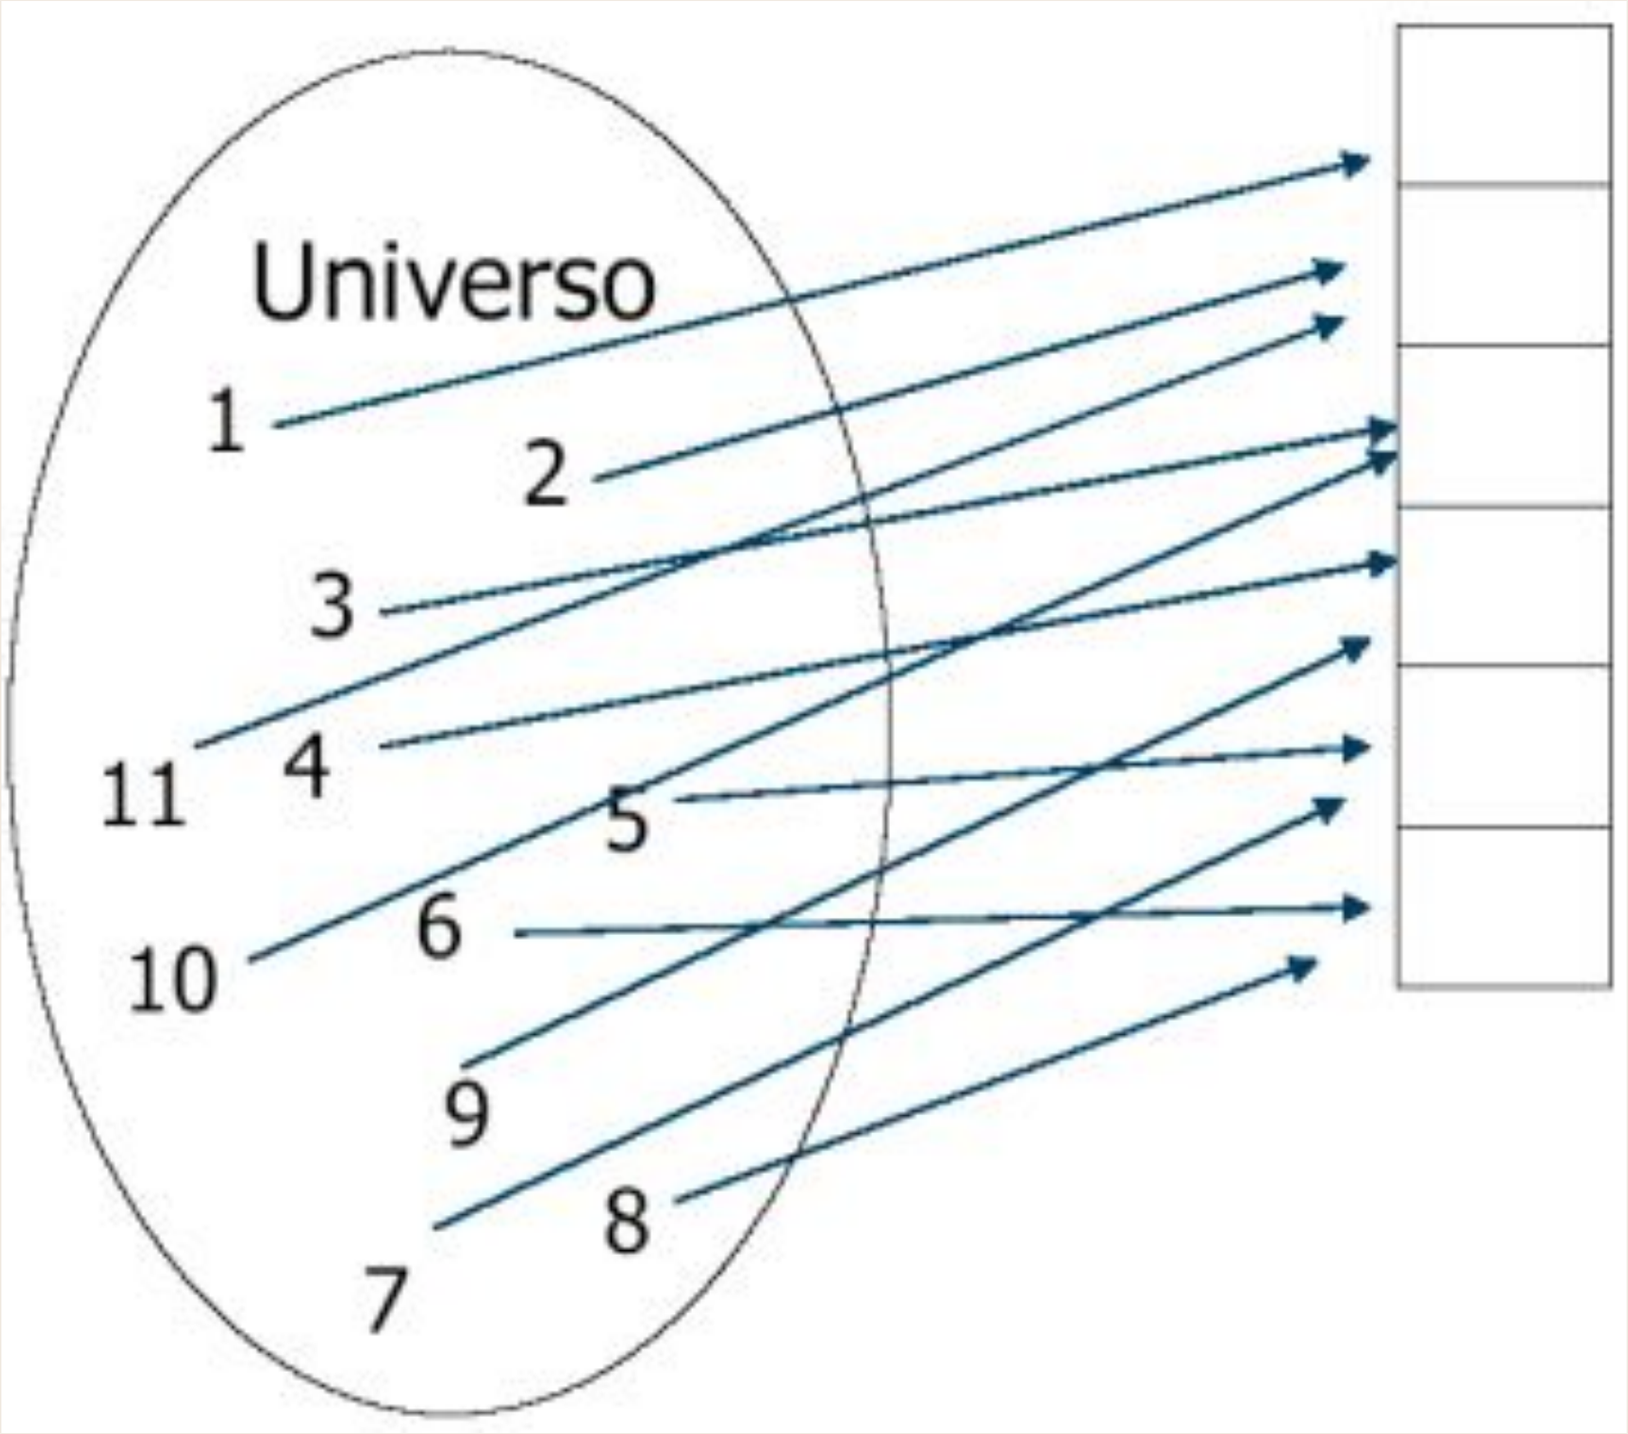

Hashing

- Função de hashing perfeita
  - Transforma diferentes chaves em diferentes posições sem colisões
- Para criar função perfeita
  - Tabela tem que conter mesmo número de posições que o número de elementos que sofreram hashing
- Quais são os problemas?
  - Pode-se não conhecer a priori o número total de elementos
  - O número possível de elementos pode ser muito maior do que o número total de elementos

Hashing

- Exemplo: Armazenamento dos empregados de uma empresa em um array
- Quantas posições o array terá que ter?
- Considerando que o número máximo de funcionários possíveis é igual à quantidade de CPFs diferentes que podem existir.
- Quantas posições o array terá que ter?

Exemplo de um uso Direto

- Exemplo: Empregados identificados por CPF
  - Class Empregado{
    int cpf;
    String nome;
    String end; ... }
- CPF como índice:
  - 1 bilhão de entradas:
  - 000 000 000 a 999 999 999
  - Empregado vet[1000000000]
- Reservar espaço para o total de possíveis empregados
- Mas, se empresa possui apenas 500 empregados, temos desperdício enorme de memória.

Uso de função hash

- Mapas ou invés de Arrays
  - HashMap
- Criptografia
  - Gravação de senha em Banco de Dados

Hashing - Divisão

- Maneira mais simples
- Usar módulo da divisão
- TSize = sizeof(table)
- h(k) = k mod TSize, caso k seja um número
- Melhor se Tsize é um número primo
  - Números primos tendem a distribuir os restos das divisões de maneira mais uniforme do que números não primos.
  - Se TSize não é um número primo pode-se utilizar função:
  - h(k) = (k mod p) mod TSize, onde p é um número primo maior que TSize
- Divisores não primos podem trabalhar bem com a condição que não tenham fatores não primos maiores do que 20 (Lum et al., 1971).

Hashing - Divisão

```
final int M1 = 97;

final int M2 = 100;

public int hash1(int key) {

    return key % M1;

}

public int hash2(int key) {

    return key % M2;

}
```

Hashing – Compressão de chaves alfanuméricas

- Utilizado quando as chaves são alfanuméricas
- Chaves são representadas utilizando sua representação interna
- Muitas vezes surge a necessidade de comprimir uma chave, dado sua representação numérica excessivamente grande
- Uma idéia útil é utilizar o operador XOR (ou exclusivo)

B	R	A	S	I	L
C2	D2	C1	D3	C9	CC
11000010	11010010	11000001	11010011	11001001	11001100

Representação hexadecimal e binária do código ASCII

Hashing – Compressão de chaves alfanuméricas

- Utilização do XOR
- Comprimindo a chave BRASIL para um total de 16 bits:
- O cálculo final do endereço é feito a partir do valor comprimido, por exemplo, utilizando uma tabela com 521 entradas:

(51917 mod 521) + 1 = 338

A	B	A xor B
0	0	0
0	1	1
1	0	1
1	1	0

```
(BR) 1100001011010010
(AS) 1100000111010011
(IL) 1100100111001100
xor  1100101011001101 = 51917(10)
```

Hashing – Compressão de chaves alfanuméricas

- Problema do método:
  - Chaves com permutações de grupos de letras/dígitos irão produzir colisões.
  - BRASIL, BRILAS, ASBRIL, ILBRAS irão produzir o mesmo endereço
  - Uma forma de contornar esse problema é executar uma operação de rotação de bits de cada grupo
  - Rotação de 1 bit no segundo grupo
  - Rotação de 2 bits no terceiro grupo
  - …

```
1000 // 1 vez
0100 // 2 vezes
0010 // 3 vezes
0001 // 4 vezes
```

Hashing - Multiplicação

- Este método utiliza uma propriedade do número conhecido como inverso da relação áurea ($ø^{-1}$), cujo valor é:

$$ø^{-1} = \frac{\sqrt{5} - 1}{2} = 0{,}61803399$$

Se calcularmos K=$\lfloor 10(i\phi^{-1} - \lfloor i\phi^{-1} \rfloor) \rfloor$, 1<= i<= 20:

Há permutação perfeita nas 10 primeiras posições

i	k	i	k
1	**6**	11	**7**
2	**2**	12	**4**
3	**8**	13	**0**
4	**4**	14	**6**
5	**0**	15	**2**
6	**7**	16	**8**
7	**3**	17	**5**
8	**9**	18	**1**
9	**5**	19	**7**
10	**1**	20	**3**

Quase acontece o mesmo nas demais posições!

Hashing - Multiplicação

- Podemos generalizar, como função de endereçamento, o valor $\lfloor m(i\phi^{-1} - \lfloor i\phi^{-1} \rfloor) \rfloor$
- Considerando *m* o tamanho da tabela e *i* o valor da chave.
- A função produzirá endereços no intervalo [0, m-1]
- Problema:
  - Computação lenta para cálculo da chave
  - Donald Knuth apresentou uma solução alternativa e igualmente satisfatória

Hashing - Multiplicação

- Segundo Donald Knuth [1973], ao invés de utilizar $ø^{-1}$, ele propõe que seja usado um valor $\frac{A}{w} \cong ø^{-1}$.
- onde w equivale ao tamanho da palavra do computador e A um inteiro tal que A e w sejam primos entre si.
  - Por exemplo, considerando A = 19 e um computador de 32 bits, temos:

$$\frac{A}{w} = \frac{19}{32} = 0{,}59357$$

  - O método deve ser aplicado em tabelas com 2^k espaços
  - Nesse exemplo, o cálculo do endereço “e” no qual deve ser instalada a chave de valor C numa tabela de 2^k registros é feito pela execução da seguinte seqüência de comandos:
    - e := C * A/w
    - e := e mod tamanho_tabela

Hashing - Enlaçamento

- Chave é dividida em diversas partes
- Partes são combinadas ou enlaçadas e frequentemente transformadas para produzir endereço alvo
- Tipos
  - Enlaçamento deslocado
  - Enlaçamento limite

Hashing – Enlaçamento deslocado

- Enlaçamento deslocado
  - Chave é dividida em partes
  - Uma parte é colocada embaixo da outra
  - Chaves são processadas a seguir
- Exemplo: código pessoal 123-45-6789
- Dividir em partes e colocar uma embaixo da outra
  - 123
    456
    789
- Processamento:
- adicionar partes
  - 123+456+789 = 1368
- dividir em módulo TSize
  - Supondo TSize = 1000
  - 1368 mod 1000 = 368

Hashing – Enlaçamento limite

- Enlaçamento limite
  - Chave é dividida em partes
  - Cada parte predeterminada será colocada em ordem inversa
- Exemplo: código pessoal 123-45-6789
- Dividir em partes e colocar uma embaixo da outra
  - 123
    456
    789
- Processamento, 456 é considerado na ordem inversa adicionar partes
  - 123+654+789 = 1566
- dividir em módulo TSize
  - Supondo TSize = 1000
  - 1566 mod 1000 = 566

Hashing – Função Meio-Quadrado

- A chave é elevada ao quadrado e parte do resultado é usada como endereço.
- Exemplo: chave 3121
  - $3121^2 = 9740641$
  - Considerando TSize igual a 1000 e parte do meio para endereçamento
  - h(3121) = 406
    - 97**406**41
- Uma máscara binária pode ser utilizada para obter posição
- Se tamanho da tabela é 1024 (em binário 10000000000)
- 31212 em binário é igual a 1001010**0101000010**11000001
- 0101000010, que é igual a 322, pode ser extraído usando máscara e uma operação de deslocamento

Extração

- Parte da chave é usada para calcular o endereço
- Exemplo:
  - Código 123-45-6789
  - Pode-se utilizar
    - primeiros quatro dígitos: 1234
    - Últimos quatro dígitos: 6789
    - Dois primeiros dígitos combinados com os dois últimos: 1289
    - ...
    - Parte escolhida deve produzir boa distribuição das chaves
    - Parte descartada deve distinguir pouco as chaves
- Exemplo:
  - Universidade onde os primeiros 3 dígitos iguais a 999 indica estudante estrangeiro
  - Estes dígitos podem ser omitidos

Transformação da Raiz

- Mudar a base do número, por exemplo, de base 10 para base nonal e dividir em módulo TSize
- Exemplo:
  - 345 em decimal é igual a 423 em base nonal
  - Se TSize igual a 100
    - h(345) = 23
  - Não evita colisões

Hasing Universal

- Qualquer função de hash está sujeita ao problema de criar chaves iguais para elementos distintos.
- Uma estratégia para minimizar as colisões é escolher aleatoriamente (em tempo de execução) uma função hash a partir do conjunto de funções cuidadosamente desenhadas.
- Escolha um primo p tal que o valor de qualquer chave k seja menor que p e maior ou igual a zero, 0 >= k < p
- p é maior que o tamanho da tabela, TSize
- Escolha, aleatoriamente, dois números inteiros a e b:
  - 0 < a <= p
  - 0 <= b <= p
  - Função hashing Universal será:
  - h(k){a,b} = ((a*k+b) mod p) mod TSize

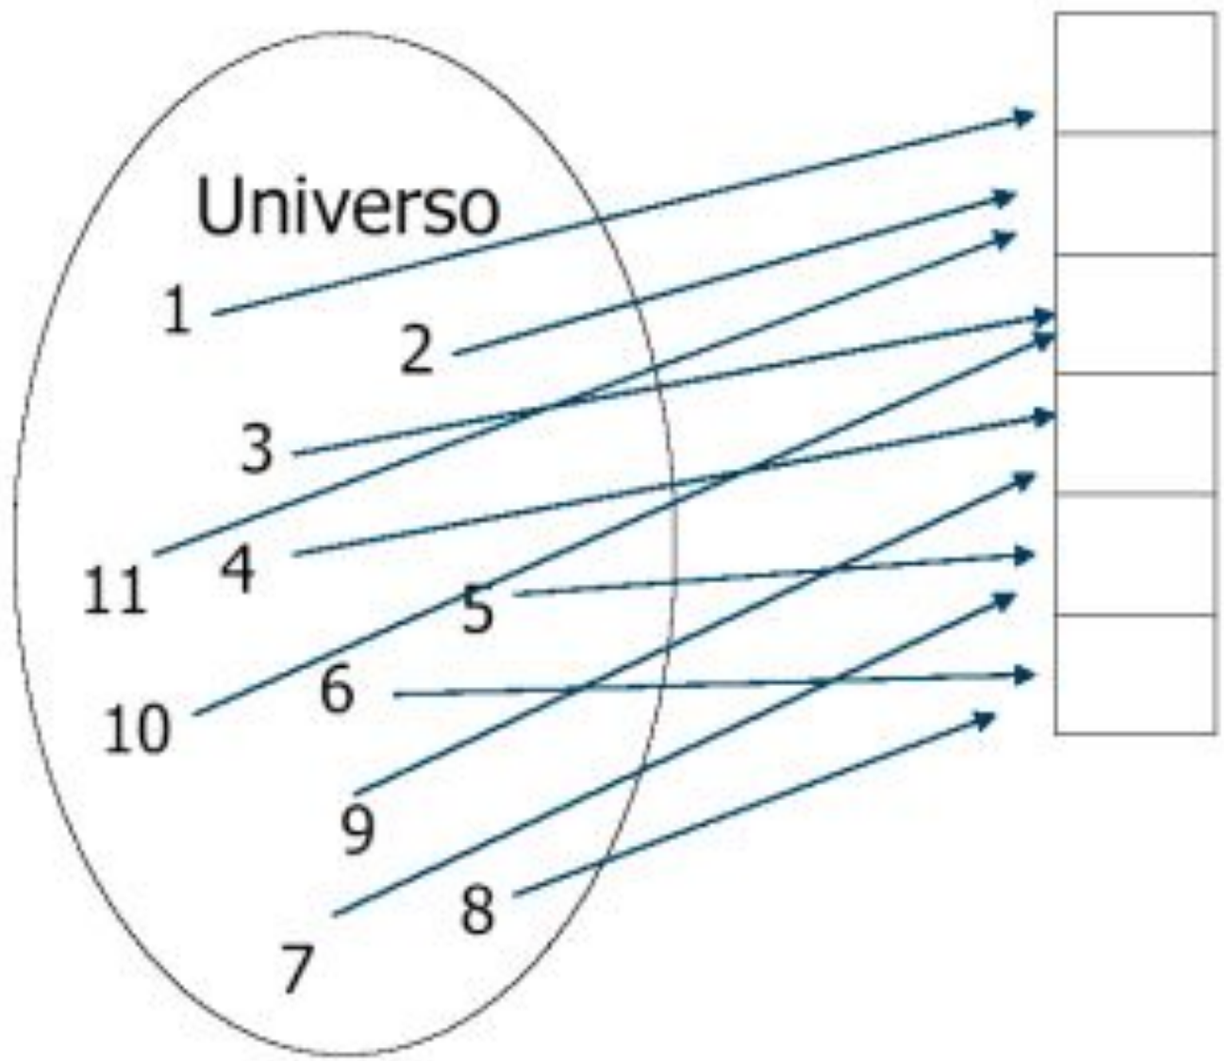

Resolução de colisões

- Colisões podem ocorrer
  - Mais de uma chave atribuída para a mesma posição
  - Exemplo: hashing que considera a primeira letra de cada nome
    - Nomes que comecem com a mesma letra teriam conflitos
- Função hashing e tamanho da tabela pode ajudar a diminuir o número de colisões

Obrigado!

Contato:

waldemar.ferreira@ufrpe.br

Classroom:

gbslcty