CORRELAÇÃO LINEAR SIMPLES

1.1 INTRODUÇÃO

Em pesquisas, frequentemente, procura-se verificar se existe relação entre duas ou mais variáveis, isto é, saber se as alterações sofridas por uma das variáveis são acompanhadas por alterações nas outras.

Por exemplo, peso vs. idade, consumo vs. renda, altura vs. peso, de um indivíduo. O termo correlação significa relação em dois sentidos (co + relação), e é usado em estatística para designar a força que mantém unidos dois conjuntos de valores. A verificação da existência e do grau de relação entre as variáveis é o objeto de estudo da correlação.

Ao se estudar uma variável o interesse eram as medidas de tendência central, dispersão, assimetria, etc. Com duas ou mais variáveis além destas medidas individuais também é de interesse conhecer se elas têm algum relacionamento entre si, isto é, se valores altos (baixos) de uma das variáveis implicam em valores altos (ou baixos) da outra variável.

Por exemplo, pode-se verificar se existe associação entre a altura de planta e altura de espiga, dose de fertilizante e produtividade, taxa de infestação de uma doença e a produtividades, etc.

A associação entre duas variáveis pode ser de dois tipos: experimental e correlacional.Uma vez caracterizada esta relação, procura-se descrevê-la sob forma matemática, através de uma função. A estimação dos parâmetros dessa função matemática é o objeto da regressão.

Os pares de valores das duas variáveis poderão ser colocados num diagrama cartesiano chamado “diagrama de dispersão”. A vantagem de construir um diagrama de dispersão está em que, muitas vezes sua simples observação já nos dá uma ideia bastante boa de como as duas variáveis se relacionam.

<u>Experimental</u>

Aplico algum tratamento.
Exemplo: Aplicar doses de calcário (tratamentos) e observar as diferenças na produtividade de milho.

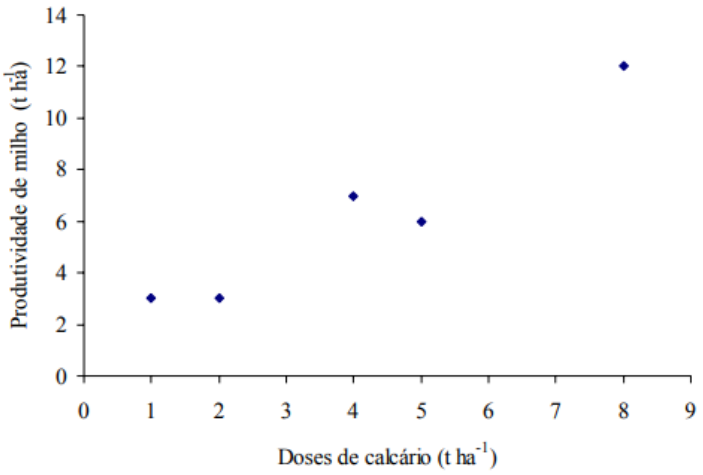

Correlacional

Não se tem nenhum controle sobre as variáveis sendo estudadas. Elas são observadas como ocorrem no ambiente natural, sem nenhuma interferência, isto é, as duas variáveis são aleatórias.
Exemplo: Altura de planta e altura de espiga.

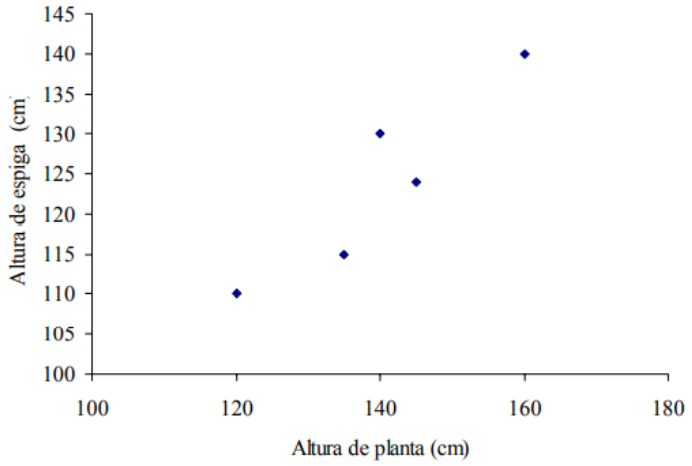

Ao estudo do relacionamento entre duas ou mais variáveis denominamos de correlação e regressão.

Se o estudo tratar apenas de duas variáveis tem-se a correlação e a regressão simples, se envolver mais do que duas variáveis, tem-se a correlação e a regressão múltiplas. A regressão e a correlação tratam apenas do relacionamento do tipo linear entre duas variáveis.

A análise de correlação fornece um número que resume o grau de relacionamento linear entre as duas variáveis.

Já a análise de regressão fornece uma equação que descreve o comportamento de uma das variáveis em função do comportamento da outra variável.

1.2. PADRÕES DE ASSOCIAÇÃO

Quando não é possível perceber uma relação sistemática entre as variáveis é dito que as variáveis são não correlacionadas, são independentes ou ainda que são ortogonais.

1.3. INDICADORES DE ASSOCIAÇÃO

- Tabela de contingência 2x2 – dá uma ideia muito superficial da associação entre as variáveis.
- Diagramas de dispersão – Fornecem uma ideia melhor da associação entre as variáveis.

Vamos considerar o seguinte exemplo para o estudar a correlação e regressão linear entre duas variáveis.

DEFINIÇÃO

Uma medida do grau e do sinal da correlação é dada pela covariância entre as duas variáveis aleatórias X e Y que é uma medida numérica de associação linear existente entre elas, e definida por:

$$\text{Cov(X, Y)} = \frac{1}{n}\left[\sum x.y - \frac{\sum x.\sum y}{n}\right].$$

É mais conveniente usar para medida de correlação, o coeficiente de correlação linear de Pearson, como estimador de xy, definido por:

$$\text{rxy} = \frac{\text{Cov}(x, y)}{\sqrt{\sigma_x \sigma_y}} = \frac{S_{xy}}{\sqrt{S_{xx}.S_{yy}}}$$

$$r_{xy} = \frac{\sum xy - \frac{\sum x.\sum y}{n}}{\left[\left[\sum x^2 - \frac{(\sum x)^2}{n}\right].\left[\sum y^2 - \frac{(\sum y)^2}{n}\right]\right]^{\frac{1}{2}}} = \frac{S_{xy}}{(S_{xx}.S_{yy})^{\frac{1}{2}}} = \sqrt{\frac{S_{xy}.S_{xy}}{S_{xx}.S_{yy}}} = \sqrt{\frac{b.S_{xy}}{S_{yy}}}$$

onde: as somas de quadrados são:

$$S_{xy} = \sum x.y - \frac{\sum x.\sum y}{n} \qquad S_{xx} = \sum x^2 - \frac{(\sum x)^2}{n} \qquad S_{yy} = \sum y^2 - \frac{(\sum y)^2}{n}$$

n = número de pares das observações.

A partir de X e Y são determinadas todas as somas necessárias para este cálculo:

	Y	X	X^2	Y^2	X . Y
	:	:	:	:	:
	:	:	;	:	:
r_{xy}	**Σy**	**Σx**	**Σx^2**	**Σy^2**	**Σ(x.y)**

O coeficiente de correlação amostral (r) pode ser calculado através da seguinte expressão:

$$r = \frac{n(\sum XY) - (\sum X)(\sum Y)}{\sqrt{n(\sum X^2) - (\sum X)^2}\sqrt{n(\sum Y^2) - (\sum Y)^2}}$$

Exemplo:

Vamos supor que você fez um experimento avaliando o efeito da aplicação de doses de calcário na produtividade de milho. Estou interessado em saber se existe associação linear entre essas variáveis e se posso estimar uma regressão linear entre essas variáveis. Os dados obtidos foram os seguintes:

Tabela 1 – Doses de calcário (t ha^{-1}) e produtividade de milho (t ha^{-1}).

Doses de calcário (t ha^{-1}) (X)	Produtividade de milho (t ha^{-1}) (Y)
1	3
2	3
4	7
5	6
8	12

Para ter uma ideia melhor, as variáveis são colocadas no que é denominado de diagrama de dispersão. Uma das variáveis (X) é representada no eixo horizontal e a outra variável (Y) no eixo vertical, conforme figura 1.

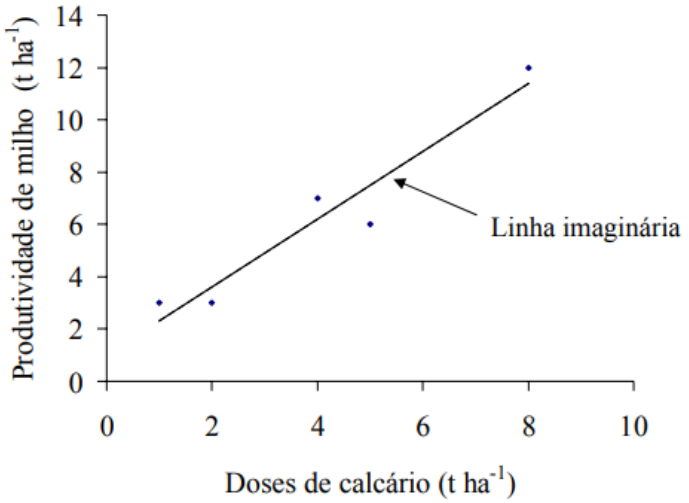

Figura 1 - Diagrama de dispersão das variáveis apresentadas na tabela 1.

Uma olhada rápida no diagrama de dispersão mostra a existência de um relacionamento entre as variáveis, com altos valores de uma das variáveis associados a altos valores da outra variável. Se não houvesse relacionamento entre elas, os pontos estariam distribuídos ao acaso no gráfico sem mostrarem alguma tendência.

1.4. O COEFICIENTE DE CORRELAÇÃO LINEAR
ou coeficiente de correlação linear de Pearson

Apesar do diagrama de dispersão nos fornecer uma ideia do tipo e extensão do relacionamento entre duas variáveis X e Y, seria altamente desejável ter um número que medisse esta relação.

Esta medida existe e é denominada de coeficiente de correlação.

- Coeficiente de correlação amostral é indicado pela letra r.
- Coeficiente de correlação populacional é indicado pela letra ρ (rho).

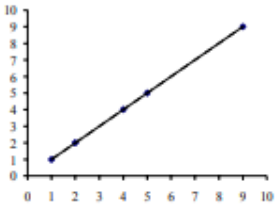

Correlação linear positiva perfeita (r =1)

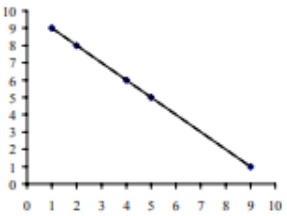

Correlação linear negativa perfeita (r = -1)

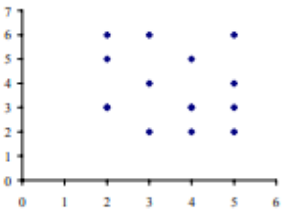

Ausência de relacionamento linear (r = 0)

O coeficiente de correlação rxy linear é um número puro que varia de –1 a +1 e sua interpretação dependerá do valor numérico e do sinal, como segue:

$r_{xy} = -1$	⇨	correlação perfeita negativa
$-1 < r_{xy} < 0$	⇨	correlação negativa
$r_{xy} = 0$	⇨	correlação nula
$0 < r_{xy} < 1$	⇨	correlação positiva
$r_{xy} = 1$	⇨	correlação perfeita positiva
$0{,}2 < r_{xy} < 0{,}4$	⇨	correlação fraca*
$0{,}4 < r_{xy} < 0{,}7$	⇨	correlação moderada*
$0{,}7 < r_{xy} < 0{,}9$	⇨	correlação forte*

*possui o mesmo significado para os casos negativos ou positivos.

Análise do Diagrama de Dispersão

O diagrama de dispersão mostrará que a correlação será tanto mais forte quanto mais próximo estiver o coeficiente de –1 ou +1, e será tanto mais fraca quanto mais próximo o coeficiente estiver de zero.

a) Correlação perfeita negativa (rxy = -1): Quando os pontos estiverem perfeitamente alinhados, mas em sentido contrário, a correlação é denominada perfeita negativa.

b) Correlação negativa (-1 < rxy < 0): A correlação é considerada negativa quando valores crescentes da variável X estiverem associados a valores decrescentes da variável Y, ou valores decrescentes de X associados a valores crescentes de Y.

c) Correlação nula (rxy = 0): Quando não houver relação entre as variáveis X e Y, ou seja, quando os valores de X e Y ocorrerem independentemente, não existe correlação entre elas.

d) Correlação positiva (0 < rxy < 1): Será considerada positiva se os valores crescentes de X estiverem associados a valores crescentes de Y.

e) Correlação perfeita positiva (rxy = 1): A correlação linear perfeita positiva corresponde ao caso anterior, só que os pontos (X, Y) estão perfeitamente alinhados.

f) Correlação espúria: Quando duas variáveis X e Y forem independentes, o coeficiente de correlação será nulo. Entretanto, algumas vezes, isto não ocorre, podendo, assim mesmo, o coeficiente apresentar um valor próximo de –1 ou +1. Neste caso a correlação é espúria.

PROPRIEDADES DO COEFICIENTE DE CORRELAÇÃO LINEAR (resumo)

As propriedades mais importantes do coeficiente de correlação são:

1. O intervalo de variação vai de -1 a +1. $-1 \leq r \leq 1$

2. O coeficiente de correlação é uma medida adimensional, isto é, ele é independente das unidades de medida das variáveis X e Y.
3. Quanto mais próximo de +1 for “r”, maior o grau de relacionamento linear positivo entre X e Y, ou seja, se X varia em uma direção Y variará na mesma direção.
4. Quanto mais próximo de -1 for “r”, maior o grau de relacionamento linear negativo entre X e Y, isto é, se X varia em um sentido Y variará no sentido inverso.
5. Quanto mais próximo de zero estiver “r” menor será o relacionamento linear entre X e Y.

1.5. HIPÓTESES BÁSICAS

A suposição básica sobre o coeficiente de correlação é que o relacionamento entre as duas variáveis seja linear. Isto é, o coeficiente de correlação é adequado para avaliar somente o relacionamento linear.

Uma segunda hipótese é que as variáveis envolvidas sejam aleatórias e que sejam medidas no mínimo em escala de intervalo. Ele não se aplica a variáveis em escala nominal ou ordinal ou quando uma das variáveis é manipulada experimentalmente, pois neste caso, a escolha dos valores experimentais vai influenciar o valor de r obtido.

Uma terceira hipótese é que as duas variáveis tenham uma distribuição conjunta normal bivariada. Isto é equivalente a dizer que para cada x dado a variável y é normalmente distribuída.

Nosso exemplo

X = Doses de calcário (t ha^{-1})
Y = Produtividade de milho (t ha^{-1})

	X	Y	X^2	Y^2	XY
	1	3	1	9	3
	2	3	4	9	6
	4	7	16	49	28
	5	6	25	36	30
	8	12	64	144	96
somatório	20	31	110	247	163
	$\Sigma X=20$	$\Sigma Y=31$	$\Sigma X^2=110$	$\Sigma Y^2=247$	$\Sigma XY=163$

$$r = \frac{5(163)-(20)(31)}{\sqrt{5(110)-(20)^2}\sqrt{5(247)-(31)^2}} = 0{,}9618$$

1.7. TESTE DE HIPÓTESE PARA O COEFICIENTE LINEAR (r)

Para o nosso exemplo queremos testar se existe ou não correlação linear entre X = Doses de calcário (t ha-1) e Y = produtividade de milho (t ha-1).

Vamos verificar se existe relacionamento linear entre as duas variáveis ao nível de 5% de significância.

a) As hipóteses a serem testadas são: H_0: $\rho = 0$ (Não existe relacionamento linear na população) H_1: $\rho \neq 0$ (Existe relacionamento linear na população) (teste bilateral)
b) Nível de significância do teste, ou erro tipo I ($\alpha = 5\%$)
c) Teste estatístico

$$t_{calc} = \frac{r}{\sqrt{\frac{1-r^2}{n-2}}} \rightarrow t_{calc} = \frac{0{,}9618}{\sqrt{\frac{1-0{,}9618^2}{5-2}}} = 6{,}09$$ Comparar com o valor de $t_{tab\ com\ n\text{-}2\ graus\ de\ liberdade}$ (Tabela 2)

d) Comparar com o valor de $t_{tab\ 5\%\ bilateral}$ ou $t_{tab\ 2{,}5\%\ unilateral\ com\ (5\text{-}2) = 3\ gl}$ ➔ $t_{tab} = 3{,}182$

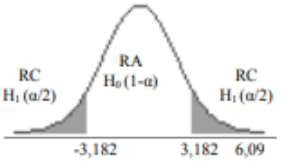

Lado esquerdo ➔ de menos infinito até -3,182 acumula uma área de 2,5% (Tabela 2).
Lado direito ➔ de 3,182 até mais infinito acumula uma área de 2,5% (Tabela 2).

e) Conclusão: tcalc (6,09) está dentro de H_1, logo rejeitamos H_0 e podemos afirmar, ao nível de 5% de significância, ou 5% de probabilidade de erro, que existe relacionamento linear na população, ou seja, o aumento da dose de calcário ocasiona um aumento na produtividade de milho. Ou ainda a correlação linear entre essas duas variáveis é significativa.
Dado que há fortes evidências de que as duas variáveis possuem um relacionamento linear pode-se então ajustar uma linha de regressão entre elas.

OBSERVAÇÕES:
Correlação não é o mesmo que causa e efeito.
Duas variáveis podem estar altamente correlacionadas e, no entanto, não haver relação de causa e efeito entre elas.
Se duas variáveis estiverem amarradas por uma relação de causa e efeito elas estarão, obrigatoriamente, correlacionadas.
O estudo de correlação pressupõe que as variáveis X e Y tenham uma distribuição normal.
A palavra simples que compõe o nome correlação linear simples, indica que estão envolvidas no cálculo somente duas variáveis.
O coeficiente de correlação linear de Pearson mede a correlação em estatística paramétrica.