UNIVERSIDADE FEDERAL RURAL DE PERNAMBUCO

ESTATÍSTICA
E
PROBABILIDADE

Professora: Milene Vieira Figueira
e-mail: Milene.figueira@ufrpe.br

Belo Jardim/PE

CAPÍTULO 1- INTRODUÇÃO

INTRODUÇÃO

A palavra estatística provém do latim *status*, que significa estado. A primeira utilização da estatística envolvia compilações de dados e gráficos que descreviam vários aspectos de um estado ou país. Tem-se notícia de que cerca de 2.000 a.C. os chineses recenseavam sua populações agrícolas. Em 1662, John Graunt publicou informes estatísticos sobre nascimentos e mortes. O trabalho de Graunt foi secundado por estudos de mortalidade e taxas de morbidade, tamanho de populações, rendas e taxas de desemprego. As famílias, os governos e as empresas se apóiam largamente em dados estatísticos. Assim é que as taxas de desemprego, de inflação, os índices do consumidor, as taxas de natalidade e mortalidade são calculadas cuidadosamente a intervalos regulares, e seus resultados são utilizados por empresários para tomarem decisões que afetam a futura contratação de empregados, níveis de produção e expansão para novos mercados.

A coleta, o processamento, a interpretação e a apresentação de dados numéricos pertencem todos ao domínio da estatística.

O CRESCIMENTO DA ESTATÍSTICA MODERNA

São várias as razões para o desenvolvimento acentuado do objetivo da estatística e da necessidade de estudá-la, nesses últimos cinquenta anos. Uma delas é a abordagem crescentemente quantitativa utilizada em todas as ciências, na engenharia e em muitas outras atividades que afetam diretamente nossas vidas. Isto inclui o uso de técnicas matemáticas na avaliação de controles de poluição, no planejamento de inventários, na análise de problemas de tráfego, no estudo dos efeitos de vários remédios, na avaliação de técnicas de ensino, na análise do comportamento competitivo de administradores e governos, no estudo de dietas e longevidade, e assim por diante. Nossa capacidade de lidar com informações numéricas aumentou enormemente com o advento de poderosos computadores. Muitos tipos de computadores são também econômicos, possibilitando a execução por pequenas empresas, estudantes de universidade e até mesmo de cursos secundários, de trabalhos sofisticados.

A outra razão é que a quantidade de dados coletados, processados e apresentados ao público, por uma razão ou outra, aumentou além de qualquer limite imaginável; julgar que parte constitui boa estatística e que parte é má estatística fica a critério do leitor. Para exercer vigilância, torna-se necessário um número cada vez maior de pessoas que participem da coleta dos dados, da sua análise e, o que é igualmente importante, de todo o planejamento preliminar. Sem este último, é difícil imaginarmos os erros que poderão ocorrer na compilação dos dados estatísticos. Os resultados de custosas pesquisas podem tornar-se inúteis, se as questões são ambíguas ou formuladas incorretamente, se são endereçadas a pessoas erradas, no lugar errado e em momento inadequado.

A ESTATÍSTICA é uma Ciência que fornece métodos para a coleta, organização, descrição, análise e interpretação de dados e para a utilização dos mesmos na tomada de decisões.

Característica importante da estatística é o uso de modelos. Estes são versões simplificadas (abstrações) de algum problema ou situação reais. A característica fundamental dos modelos é o fato reduzirem situações complexas a formas mais simples e mais compreensíveis, focalizando nossa atenção apenas em alguns detalhes de uma dada situação.

VARIÁVEIS

A cada fenômeno corresponde um número de resultados possíveis. Assim, por exemplo:

- para o fenômeno 'sexo' são 2 os resultados possíveis;
- o número de crianças em uma família pode ser expresso por números naturais: 0, 1, 2 , ...,n;
- para o fenômeno 'estatura' temos uma situação diferente, pois os resultados podem tomar um número infinito de valores numéricos dentro de um intervalo (depende da precisão da medida).

Logo

Variável é um símbolo, como x, y, z, t, que pode assumir qualquer valor de um conjunto de resultados possíveis de um fenômeno.

ou

Variável é toda a característica ou condição que pode ser mensurada ou observada.

A – <u>Variável qualitativa</u>

Quando uma característica ou variável é não numérica. Aquelas que apresentam como possíveis realizações uma qualidade (ou atributo) do indivíduo pesquisado. As variáveis qualitativas podem ser classificadas como:

a) **nominal**, para a qual não existe nenhuma ordenação possível; e
b) **ordinal**, para a qual existe uma ordem nos seus resultados.

Exemplos de variáveis qualitativas:

- cor de um objeto;
- religião;
- naturalidade;
- cor dos olhos;
- faixa etária (infância, adolescência, adulto, velho);
- classe social (baixa, média, alta).

Quando os dados são qualitativos, o interesse encontra-se, normalmente, na quantidade ou na proporção de cada categoria em relação a um todo.

Exemplo: 23% das pessoas preferem carro de cor branca.

B – <u>Variável quantitativa</u>

Quando a variável tem valor numérico mensurada com unidade.

Exemplos de variáveis quantitativas:

- quantidade de alunos por sala de aula.
- número de ações de uma determinada empresa;
- tempo de duração de uma bateria de telefone celular.

As variáveis quantitativas podem ser

a) **discretas**: são as que podem assumir apenas determinados valores.
   Exemplos: - número de juntas defeituosas.
   - número de passageiros em ônibus de Caxias do Sul a Porto Alegre.

b) **contínuas**: são as que podem assumir qualquer valor dentro de uma determinada faixa de valores, e representam uma medida (em qualquer grau de precisão). Na prática, entretanto, os mecanismos de medição têm precisão limitada, tal que os dados coletados de variáveis contínuas são necessariamente discretos.

Exemplos: - volume de ar contido num ambiente fechado;
- tempo de voo entre duas cidades;
- peso (massa).

POPULAÇÃO E AMOSTRA

À Estatística não interessa concluir a respeito de indivíduos isoladamente observados, mas sim de grupos ou conjuntos, porque seu objetivo é o estudo da chamada **população.**

População consiste na totalidade de unidades de observação a partir das quais se deseja tomar uma decisão. Também é chamada de *universo*.

Se a população é pequena, é razoável observar toda ela. Todavia, examinar a população inteira nem sempre é viável. Por esse motivo, o estudo estatístico inicia-se com a coleta de parte de uma população, denominada **amostra**, constituída de um número finito de unidades de observação e que devem ter as mesmas características da população.

CENSO é uma coleção de dados relativos a todos os elementos de uma população.

No ambiente das ciências exatas, os dados quase sempre são uma amostra que foi selecionada a partir de alguma população. Geralmente esses dados são coletados de uma das duas formas a seguir:

- **estudo observacional** – os dados são obtidos à medida que se tornam disponíveis.

Exemplo: Medir e registrar o desempenho de um processo de fabricação de peças automotivas.

- **experimento planejado** – observa e registra dados onde são feitas variações propositais nas variáveis controláveis de algum processo

Exemplo: Medir e registrar concentração de certo componente químico a partir de avriações na temperatura de uma reação química.

ARREDONDAMENTO DE DADOS

Muitas vezes é necessário ou conveniente suprimir unidades inferiores às de determinada ordem. Essa técnica é chamada arredondamento de dados.

1º) Quando o primeiro algarismo a ser abandonado é **0**, **1**, **2**, **3** ou **4**, fica inalterado o último algarismo a permanecer.

Exemplos: a) 92,24 passa a 92,2
b) 5,6254 passa a 5,625 (para a precisão de milésimos)
c) 5,6254 passa a 5,6 (para a precisão de décimos)

2º) Quando o primeiro algarismo a ser abandonado é **5**, **6**, **7**, **8** ou **9**, aumenta-se de uma unidade o algarismo a permanecer.

Exemplos: a) 13,67 passa a 13,7 b) 2,99 passa a 3,0 c) 41,08 passa a 41,1
d) 2,352 passa a 2,4 e) 25,6501 passa a 25,7 f) 24,75 passa a 24,8

Observações

1) Não devemos fazer arredondamentos sucessivos.

Exemplo: 17,3452 passa a 17,3 e não a 17,35 e por fim a 17,4

Se tivermos necessidade de um novo arredondamento, fica recomendada a volta aos dados originais.

2) Cuidado com o arredondamento em situações como:
Dado o valor 2,46 milhões de reais, se arredondarmos para 2,5 milhões de reais estamos alterando a quantidade em R$ 40.000,00.

EXERCÍCIOS

Classificar cada medida abaixo em variável quantitativa (contínua ou discreta) ou variável qualitativa (ordinal ou nominal):

a) Peso do conteúdo de pacote de farinha: .....
b) Diâmetro de um rolamento: .....
c) Número médio diário de clientes potenciais visitados por um vendedor durante o último mês: .....
d) Altura h de um indivíduo: .....
e) Volume de gás produzido numa reação química: .....
f) Vida média de lâmpadas: .....
g) Comprimento de 1000 parafusos: .....
h) Número de livros de uma biblioteca : .....
i) Satisfação com o governo: excelente, bom, regular, péssimo: .....
j) Estilo de construção de casa: colonial, moderno, contemporâneo, europeu: .....
k) Número de elementos químicos de um composto orgânico: .....
l) Classificação de restaurante (número de estrelas): .....
m) Número de artigos defeituosos produzidos por uma determinada máquina: .....
n) Temperatura de um líquido .....
o) Índice de massa corporal (IMC): .....
p) Densidade populacional (habitantes por km^2): .....
q) Time de futebol (Caxias, Grêmio, Internacional, Juventude): .....
r) Concentração de colesterol total no sangue (mg/dL): .....
s) Religião (católico, protestante, evangélico, islâmico): .....
t) Resposta de questionário (fumante/não-fumante): .....

CAPÍTULO 2 – LEVANTAMENTO DE DADOS E TÉCNICAS DE AMOSTRAGEM

INTRODUÇÃO

Muitas vezes é impraticável para o pesquisador observar todos os elementos do grupo que pretende estudar. É preciso, então, recorrer à pesquisa com uma parte desse todo.

Todos os elementos do grupo a ser estudado constituem a população (finita ou infinita). A parte da população efetivamente examinada é a amostra.

Suponhamos uma pesquisa sobre o nível de escolaridade de um grupo de 800 pessoas. Nesse caso, a população é o conjunto das 800 pessoas. Se sentirmos desnecessário ou impossível examinar os 800 elementos, podemos recorrer à amostragem, ou seja, podemos examinar alguns desses elementos.

É claro que se escolhermos apenas dois desses 800 elementos, corremos o risco de selecionar exatamente dois elementos com as mesmas características. Se os dois forem analfabetos, por exemplo, podemos concluir que todos os elementos da população também o são.

Observe que, qualquer que seja a amostra, sempre corremos o risco de chegar a conclusões erradas, mas esse risco diminui a medida que aumenta a quantidade de elementos a serem examinados.

Os estudos que utilizam métodos estatísticos vão desde os que são bem concebidos e executados, dando resultados confiáveis, aos que são concebidos deficientemente e mal executados, levando a conclusões enganosas e sem qualquer valor real. Eis alguns pontos importantes para o planejamento de um estudo eficaz de produzir resultados válidos:

1- Identificar com precisão a questão a ser respondida e definir com clareza a população de interesse.
2- (Tentar) Identificar os fatores importantes que afetam o problema em questão.
3- Propor um modelo para o problema
4- Estabelecer um plano adequado para coleta de dados. Esse plano deve descrever detalhadamente a realização de um *estudo observacional* ou de um *experimento*, e deve ser elaborado cuidadosamente, de modo que os dados coletados representem efetivamente a população em questão.
5- Coletar os dados. Devemos ser extremamente cautelosos, para minimizar os erros que podem resultar de uma coleta tendenciosa de dados.
6- Analisar os dados e tirar conclusões. Identificar também possíveis fontes de erros. As diferenças entre as amostras são chamadas de **erro amostral**, embora nenhum erro tenha ocorrido.

AMOSTRAGEM ALEATÓRIA

Para que nossas inferências sejam válidas, a amostra tem de ser representativa da população. Amostras com observações que sejam convenientes ou exerçam julgamento na seleção podem introduzir alguma tendência. Para evitar essas dificuldades é desejável selecionar uma amostra aleatória como o resultado de algum mecanismo de chance.

1) AMOSTRAGEM ALEATÓRIA SIMPLES

Em uma **amostra aleatória**, os elementos da população são escolhidos de tal forma que cada um deles tenha *igual chance* de figurar na amostra. (Escolhe-se uma **amostra aleatória simples** de *n* elementos, de maneira que toda amostra de tamanho *n* possível tenha a mesma chance de ser escolhida).

As amostras aleatórias podem ser escolhidas por diversos métodos, inclusive a utilização de programas computacionais para gerar números aleatórios.

Este tipo de amostragem é equivalente a um sorteio lotérico.

Na prática, a amostragem aleatória simples pode ser realizada numerando-se a população de ***1*** a ***N*** e sorteando-se, a seguir por meio de um dispositivo aleatório qualquer, ***n*** números dessa sequência, os quais corresponderão aos elementos pertencentes à amostra.

2) AMOSTRAGEM SISTEMÁTICA

Quando os elementos da população já se acham ordenados, não há necessidade de construir um sistema de referência. São exemplos os prontuários médicos de um hospital, dos prédios de uma rua, as linhas de produção e etc. Nestes casos, a seleção dos elementos que constituirão a amostra pode ser feita por um sistema imposto pelo pesquisador. A esse tipo de amostragem denominamos **sistemática.**

Assim, no caso de uma linha de produção, podemos, a cada dez itens produzidos, retirar um para pertencer a uma amostra da produção diária. Neste caso estaríamos fixando o tamanho da amostra em 10% da população.

Exemplo 2.1: No caso de uma linha de produção, podemos, a cada dez itens produzidos, retirar um para pertencer a uma amostra da produção diária. Neste caso estaríamos fixando o tamanho da amostra em 10% da população. Esse método é simples e utilizado com frequência.

Exemplo 2.2: Deseja-se retirar uma amostra de n = 12 unidades de observação de uma população de tamanho N = 874. O intervalo de seleção é, então, 874/10 = 72,8(aproxima-se para menos, senão se ultrapassará a ordem da última unidade). Desse modo, vão-se contando as unidades de observação e escolhem-se aquelas que estiverem, por exemplo, nas seguintes posições: 72, 114, 216, 288, 360, 432, 504, 576, 648, 720, 792 e 864.

3) AMOSTRAGEM ESTRATIFICADA PROPORCIONAL

A amostragem estratificada proporcional é recomendada quando existe uma divisão natural da população em grupos com números de elementos diversos.

Com a **amostragem estratificada**, subdividimos a população em, no mínimo, duas subpopulações (ou estratos) que compartilham das mesmas características (como sexo) e, em seguida, extraímos uma amostra de cada estrato.

Exemplo 2.3: Uma empresa cadastra seus funcionários através do grau de instrução. A tabela a seguir apresenta essa situação.

Se desejarmos uma amostra com 84 pessoas, elas ficariam distribuídas conforme a última coluna da tabela:

Grau de instrução	População	Amostra
	Número de pessoas*	Número de pessoas
Ensino fundamental completo	187	
Ensino médio incompleto	125	
Ensino médio completo	69	
Ensino superior incompleto	58	
Ensino superior completo	42	
Pós graduação	13	
Total		

*Dados fictícios

4) AMOSTRAGEM POR CONGLOMERADOS

Nesse tipo de amostragem a população total é subdividida em várias partes relativamente pequenas, e algumas dessas subdivisões, ou conglomerados, são selecionadas aleatoriamente e, finalmente, tomamos todos os elementos desse conglomerado para integrarem a amostra global.

OBESRVAÇÃO

AMOSTRAGEM POR JULGAMENTO (não aleatória)

Os elementos escolhidos são aqueles julgados como típicos da população que se deseja estudar. Por exemplo, num estudo sobre a produção científica dos departamentos de ensino de uma universidade, um estudioso sobre o assunto pode escolher os departamentos que ele considera serem aqueles que melhor representam a universidade em estudo.

EXERCÍCIOS

1) As afirmações a seguir contêm erro(s). Identifique-o(s).

a) É sempre melhor fazer um censo do que extrair uma amostra.
b) Numa certa pesquisa, extraímos 100 dos 4.000 alunos de uma escola. Para conseguirmos a mesma precisão de resultados, numa cidade com 40.000 habitantes, precisamos de uma amostra de 1.000 habitantes.
c) Para sabermos se os frequentadores de um *shopping* lavam as mãos após utilizarem o banheiro, o ideal é entrevistá-los na saída do banheiro.
d) Uma pesquisa de opinião pública feita com brasileiros num *site* popular conseguiu 17.536 respostas. A maioria dos respondentes disse que está insatisfeita com o governo federal. Como o tamanho da amostra foi tão grande, podemos ter certeza de que a maioria da população brasileira pensa da mesma maneira.
e) Para avaliar o funcionamento de uma máquina, toma-se uma amostra aleatória durante a primeira hora de funcionamento da mesma.
f) A melhor forma de realizarmos uma pesquisa com donas de casa a nível estadual é enviando o formulário de coleta de dados pelo correio.

2) Numa escola da região, para estudar a preferência em relação a refrigerantes, sortearam-se 150 estudantes entre os 1000 matriculados. Responda:
a) Qual a população envolvida na pesquisa?
b) Que tipo de amostragem foi utilizado e qual é a amostra considerada?

3) Em uma certa cidade, quer-se estudar o interesse despertado por um programa de TV entre os alunos de 7 anos de idade das escolas de ensino fundamental. Para isso, pretende-se levantar uma amostra de 300 crianças. A partir dos dados abaixo, estratifique a amostra:

ESCOLA	POPULAÇÃO
A	400
B	300
C	350
D	450
E	520

4) Em uma cidade com 30.000 habitantes deseja fazer-se uma pesquisa sobre a preferência por tipo de lazer entre pessoas de 20 anos de idade, levando em conta o sexo a que pertencem.
a) Qual a população envolvida na pesquisa?
b) Supondo que na cidade haja 5500 mulheres e 6000 homens, com 20 anos, determine uma amostra com 1200 pessoas.

5) Uma população encontra-se dividida em três estratos, com tamanhos, respectivamente 40, 100 e 60 indivíduos. Sabendo que, ao ser realizada uma amostragem estratificada proporcional, nove elementos foram retirados do 3º estrato, determine o número total de elementos da amostra.

6) Em uma empresa existem 250 funcionários, sendo 35 na linha de produção A, 32 na linha de produção B , 30 na linha de produção C, 28 na linha de produção D , 35 na linha de produção E, 32 na linha de produção F, 31 na área administrativa e 27 na engenharia. Obtenha uma amostra de 40 funcionários.

7) Uma empresa apresenta o seguinte quadro de funcionários:

Setor	Número de funcionários	
	Masculino	**Feminino**
Produção	80	60
Engenharia	11	4
Administração	13	17
Qualidade	4	5
Total	108	86

Obtenha uma amostra estratificada proporcional de 35 funcionários.

8) Uma empresa que embala biscoitos realiza o controle de qualidade selecionando aleatoriamente 10 caixas da produção total diária e pesando os pacotes. Depois, eles abrem um pacote de cada caixa e inspecionam o conteúdo.
A partir dessas informações, identifique se possível:
a) a população
b) as variáveis da população em questão
c) a(s) amostra(s)
d) o método amostral e dizer se foi aleatório ou não
e) qualquer fonte potencial de tendenciosidade que você pode detectar

CAPÍTULO 3 - GRÁFICOS ESTATÍSTICOS

INTRODUÇÃO

Os métodos gráficos tem encontrado um uso cada vez maior devido ao seu apelo visual. Normalmente, é mais fácil para qualquer pessoa entender a mensagem de um gráfico do que aquela embutida em tabelas ou sumários numéricos.

A representação gráfica de uma série de dados permite, ao mesmo tempo, uma visão geral e alguma caracterização particular da população por meio de uma correspondência entre as categorias ou valores e uma determinada figura geométrica, de tal modo que cada valor ou categoria é representado por uma figura proporcional.

Os principais tipos de gráficos são diagramas, cartogramas e pictogramas.

GRÁFICO EM LINHA

Os gráficos de linha são bastante utilizados na identificação de tendências de aumento ou diminuição dos valores numéricos de um fenômeno. Assim, vamos encontrar com frequência esse tipo de representação em análises tais como lucros de empresas, incidência de doenças, índice de crescimento populacional ou de mortalidade infantil, índices de custo de vida, comportamento do fenômeno ao longo do tempo etc.

No eixo horizontal, marca-se o tempo.

Exemplo 3.1: A tabela a seguir apresenta a variação (%) do índice de preços ao consumidor amplo

Tabela: Índice de preços ao consumidor amplo - IPCA

Mês	No mês	Últimos 12 meses
Fevereiro 2010	0,78	4,38
Março 2010	0,52	5,17
Abril 2010	0,57	5,26
Maio 2010	0,43	5,22
Junho 2010	0,0	4,84
Julho 2010	0,01	4,60
Agosto 2010	0,04	4,49
Setembro 2010	0,45	4,70
Outubro 2010	0,75	5,20
Novembro 2010	0,83	5,63
Dezembro 2010	0,63	5,91
Janeiro 2011	0,83	5,95

Fonte: IBGE

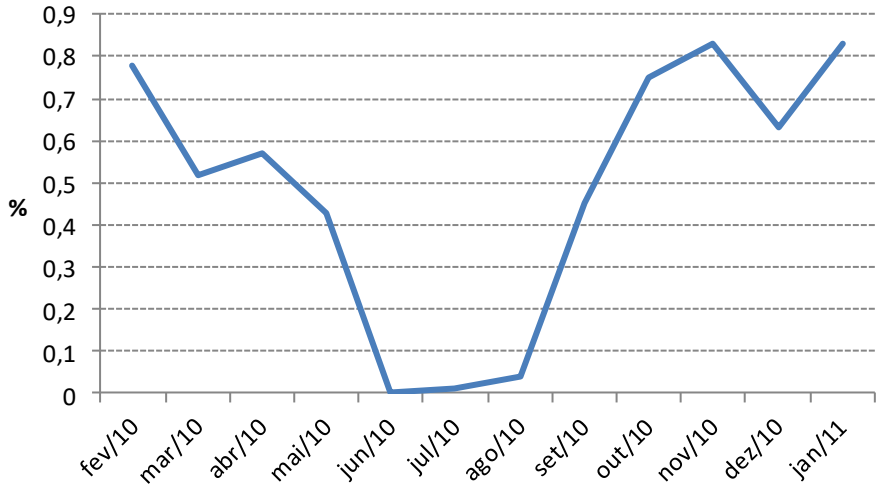

Figura: Índice de Preços ao Consumidor Amplo – IPC
Fonte: IBGE

Exemplo 3.2: O gráfico a seguir apresenta a concentração de um componente A ao longo do tempo de uma reação química.

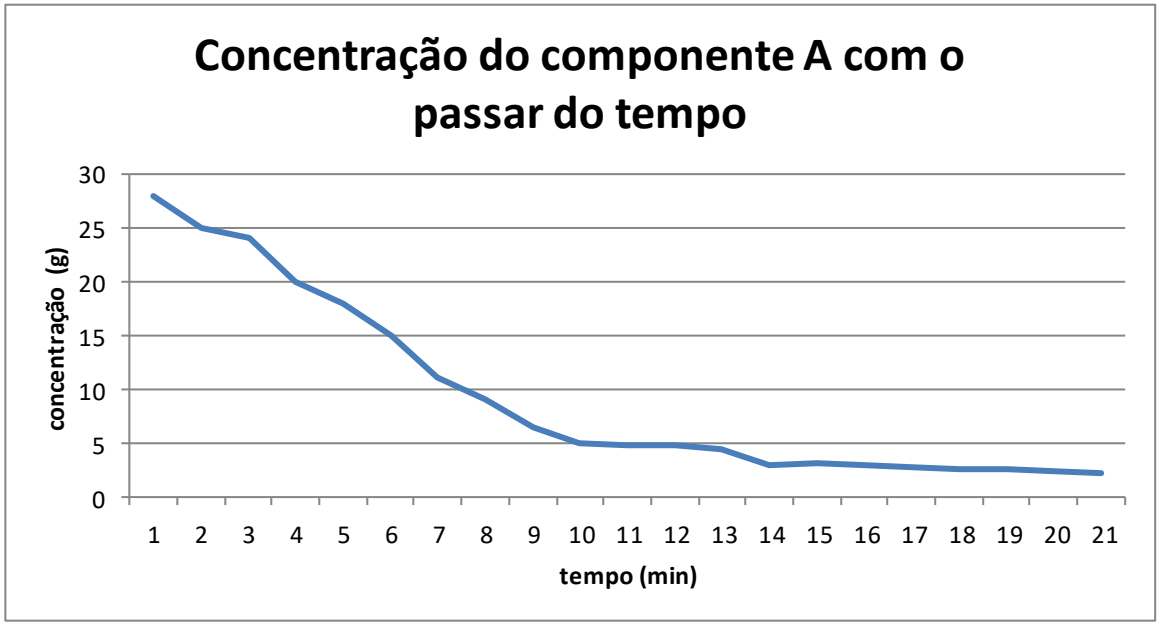

Podemos, ainda, representar mais de um fenômeno num mesmo sistema de eixos.

Exemplo 3.3:

Tabela: Taxa de desemprego na grande São Paulo

Ano	Homens (%)	Mulheres (%)
1996	13,5	17,1
1997	14,1	18,3
1998	16	21,0
1999	17,5	21,8
2000	15,1	20,8
2001	15	20,7

Fonte: EXAME (MEU DINHEIRO), Abril 2002.

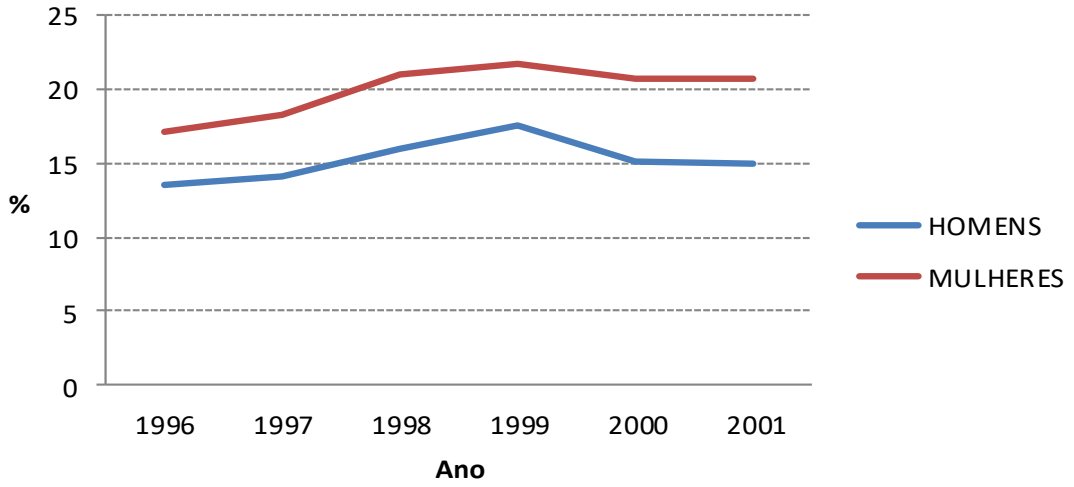

Figura: Taxa de desemprego na grande São Paulo
Fonte: EXAME (MEU DINHEIRO), Abril 2002.

Exemplo 3.4: O gráfico a seguir apresenta a concentração de um componente A e um componente B ao longo do tempo de uma reação química.

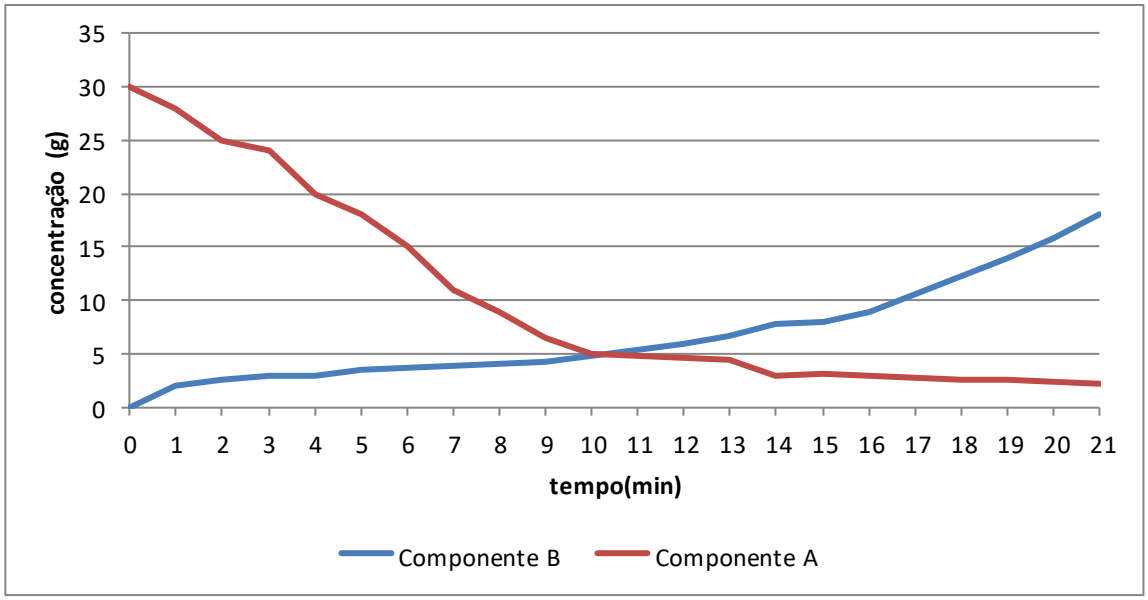

GRÁFICO EM COLUNAS E GRÁFICO EM BARRAS

É a representação de uma série por meio de retângulos, dispostos verticalmente (em colunas) ou horizontalmente (em barras).

Quando em colunas, os retângulos têm a mesma base e as alturas são proporcionais aos respectivos dados. Um gráfico de colunas mostra as alterações dos dados em um intervalo de tempo ou ilustra comparações entre categorias, as quais são organizadas de maneira horizontal e os valores de maneira vertical para enfatizar a variação ao longo do tempo.

Quando em barras, os retângulos têm a mesma altura e os comprimentos são proporcionais aos dados. Um gráfico de barras ilustra comparações entre categorias; estas são organizadas verticalmente, enquanto os valores têm disposição horizontal, para enfatizar a comparação de valores e dar menos ênfase ao tempo.

No gráfico de colunas e de barras, também é indiferente a ordem de apresentação dos retângulos, por se tratar de uma série ordenada segundo uma característica qualitativa. Nesses casos, não há, em geral, uma ordem única, técnica e logicamente admissível, podendo ocorrer diversas ordens, correspondentes a diversos critérios.

Exemplo 3.5: A tabela a seguir apresenta dados relativos a uma pesquisa realizada em uma cidade da região. A questão era "Como você fica sabendo das promoções da loja XX?"

Tabela: Como você fica sabendo das promoções da loja XX?

Fonte	Frequência*	%
TV	68	44,3
Amigos	65	42,9
Internet	36	23,6
Jornal	31	20,7
Rádio	28	18,7
Parentes	23	14,9
Encartes de jornal	13	8,7
Outros	1	0,9

*Múltiplas respostas
Fonte: A autora

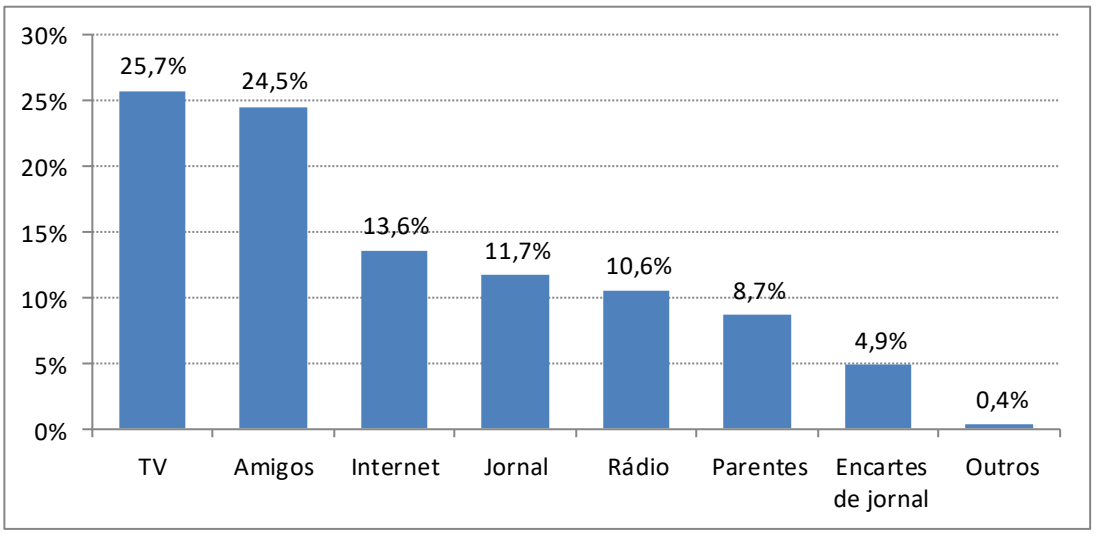

Figura: Como você fica sabendo das promoções da loja XX? (Múltiplas respostas)
Fonte: A autora

Exemplo 3.6: Foi perguntado a um grupo de alunos de Ensino Médio “Como seu curso de graduação seria financiado se você continuasse estudando?”. O gráfico a seguir apresenta o resultado ao questionamento.

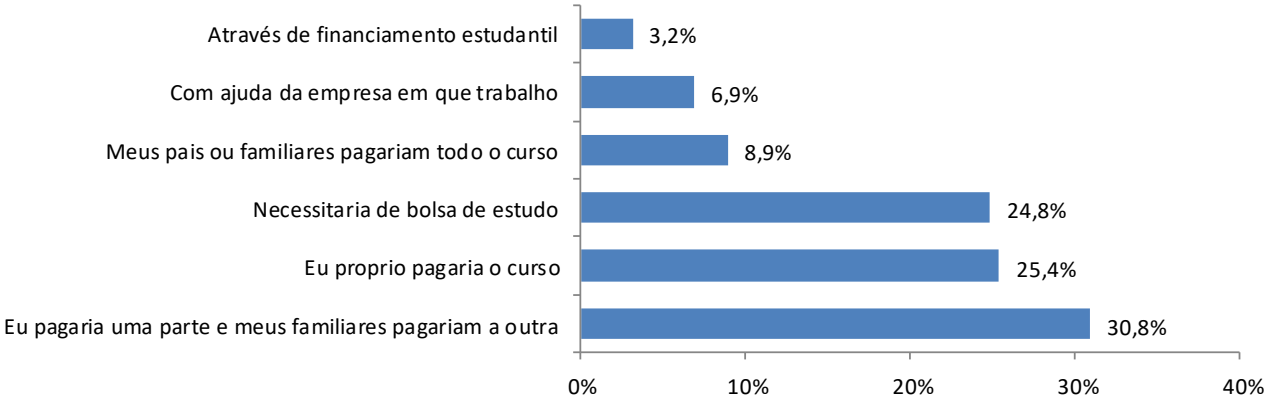

Figura: Como seus estudos seriam financiados?

Exemplo 3.7:

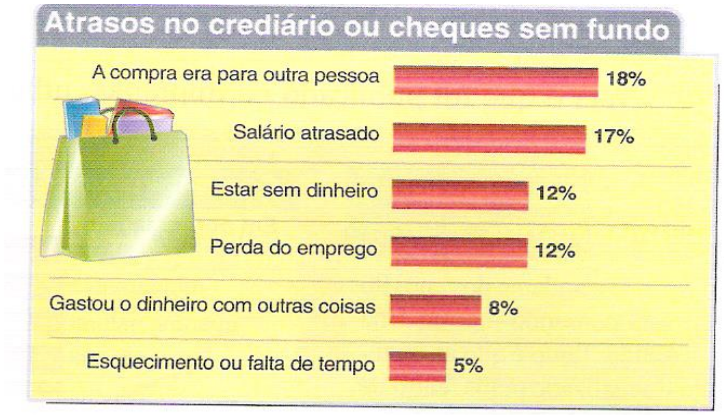

GRÁFICO EM SETORES (pizza)

A Estatística recorre com frequência a esse tipo de gráfico, que consiste em distribuir num círculo setores (ou categorias) proporcionais aos dados do problema.

Exemplo 3.8: O gráfico a seguir apresenta dados de uma pesquisa feita com uma amostra de microempresários da região, onde lhes foi questionado sobre o que faltava às suas empresas para serem mais competitivas.

Fonte: A autora

O total é representado pelo círculo, que fica dividido em tantos setores quantas são as partes. As áreas dos setores são proporcionais aos dados da série.

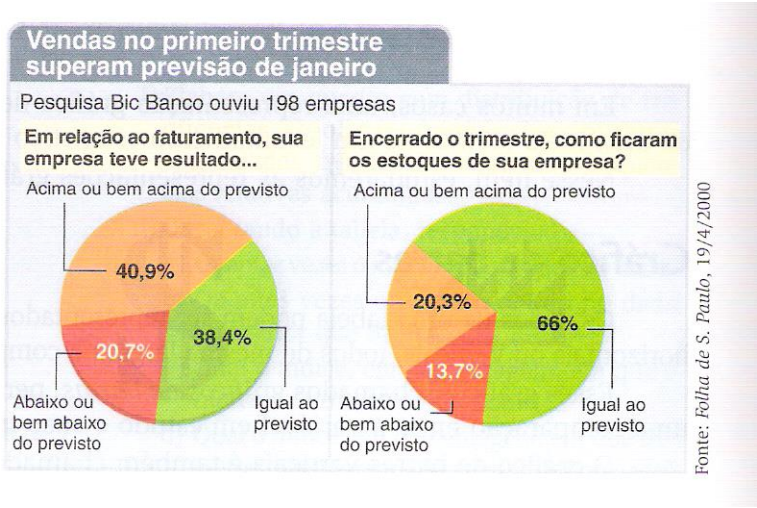

DIAGRAMA DE DISPERSÃO

O gráfico de dispersão apresenta duas variáveis numéricas. Então temos pontos (pares ordenados) representando a relação entre essas variáveis.

Exemplo 3.9: Supõe-se que o conteúdo de hidrogênio seja um fator importante na porosidade de fundições de liga de alumínio. A tabela a seguir apresenta os dados sobre conteúdo de hidrogênio e porosidade numa determinada série de testes e o respectivo gráfico.

Conteúdo de hidrogênio	0,18	0,2	0,21	0,21	0,21	0,22	0,23	0,23	0,24	0,24	0,25	0,28	0,3	0,37
Porosidade	0,46	0,7	0,41	0,45	0,55	0,44	0,24	0,47	0,22	0,8	0,88	0,7	0,72	0,75

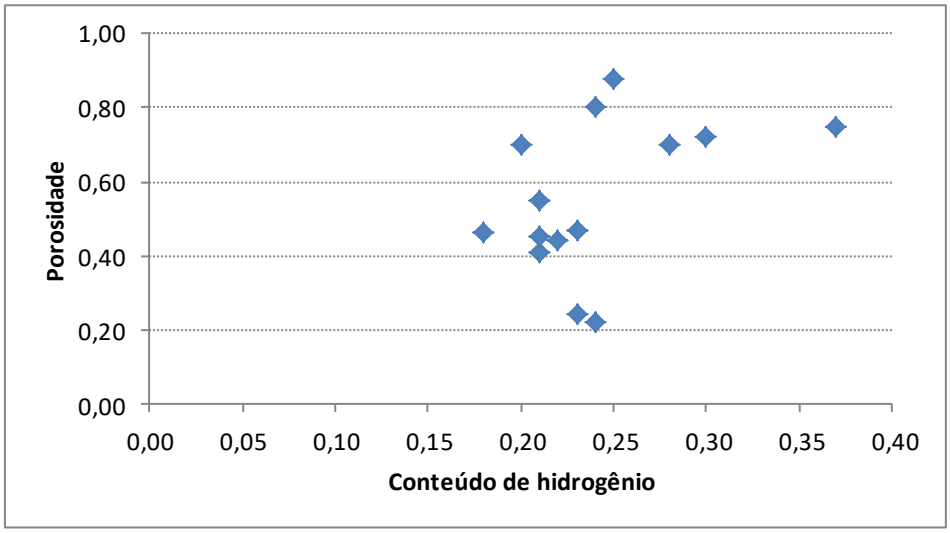

GRÁFICOS QUE ENGANAM

Quando observar um gráfico ou uma tabela, particularmente como parte de um anúncio, seja cauteloso. Observe as escalas usadas nos eixos horizontal e vertical. Pode-se distorcer a verdade com as técnicas estatísticas.

No exemplo a seguir, têm-se os ganhos médios mensais de certa categoria de profissionais.

Exemplo 3.10

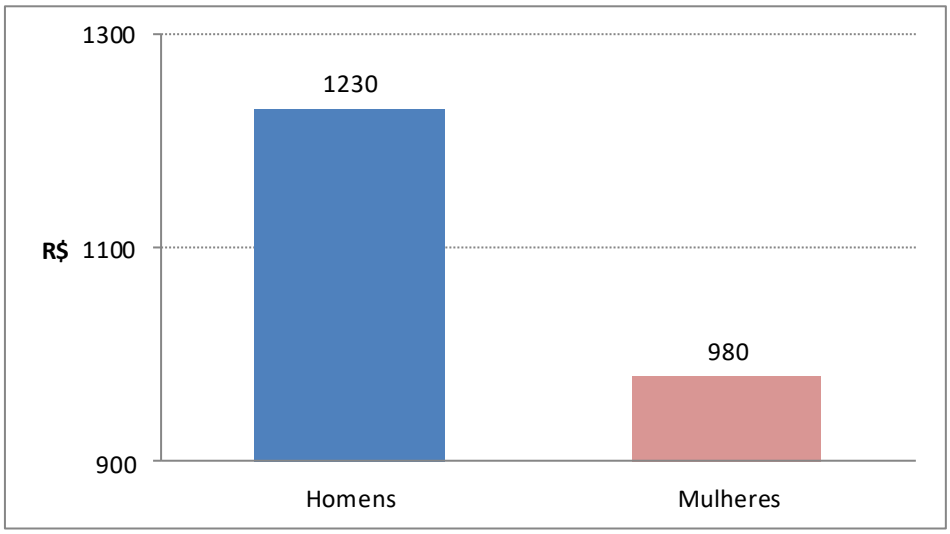

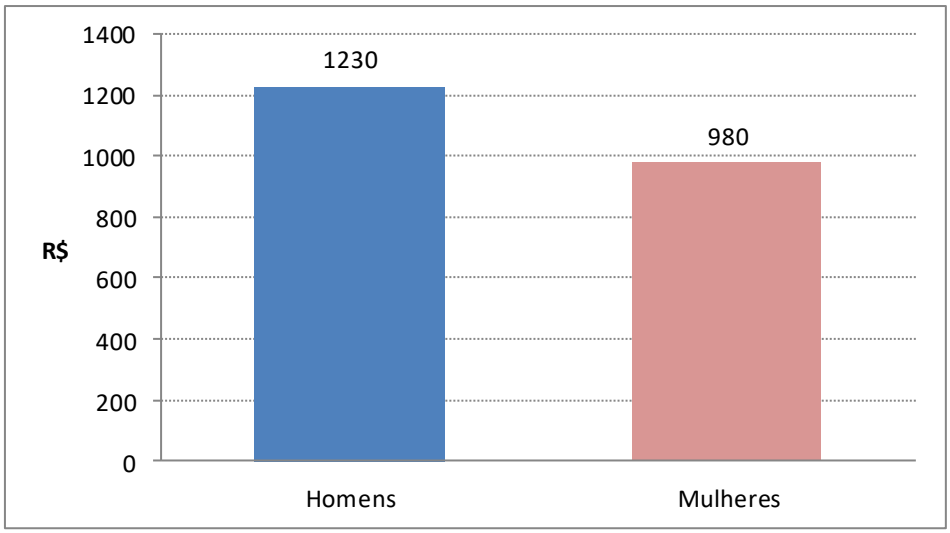

Qual a primeira impressão que se tem ao compararmos os dois gráficos?

Exemplo 3.11

Os gráficos a seguir apresentam o grau de satisfação dos estudantes com o transporte coletivo da cidade (dados fictícios).

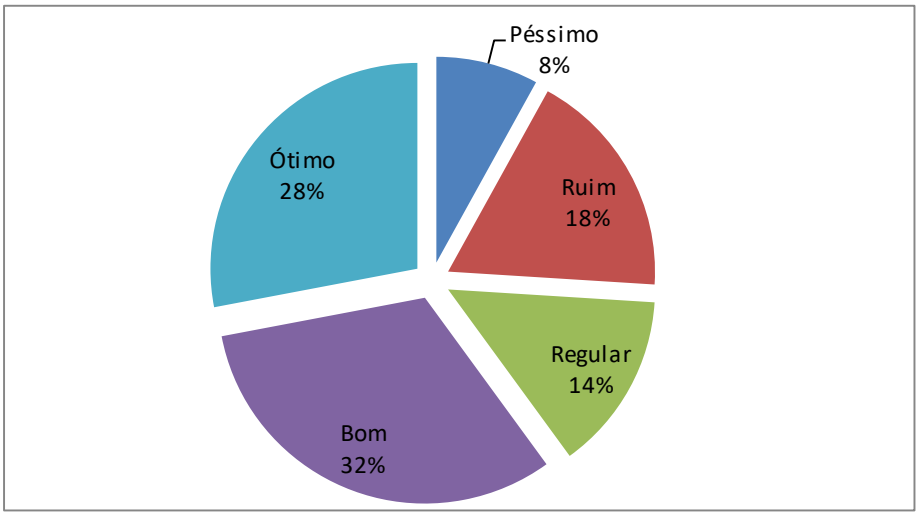

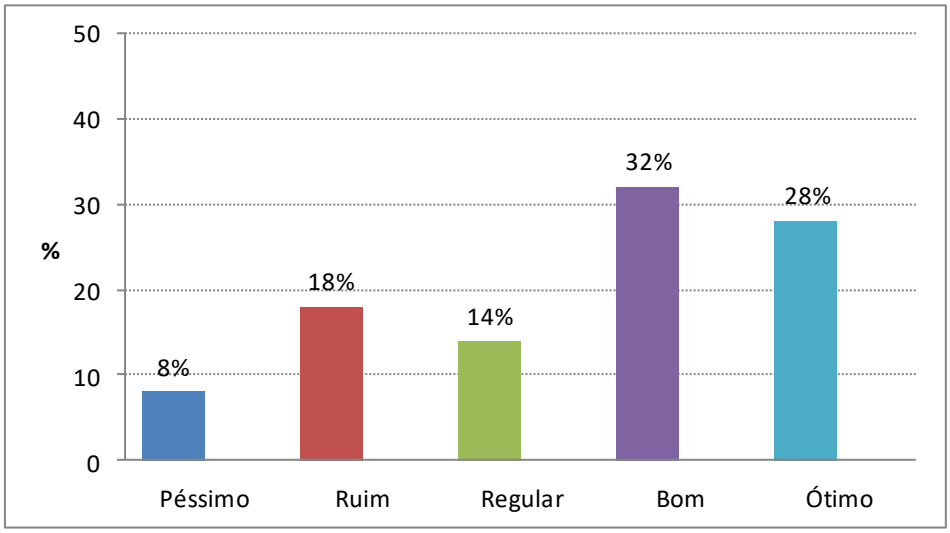

Em qual dois dois a leitura é mais fácil?

CARTOGRAMA

É a representação sobre uma carta geográfica.

Esse gráfico é empregado quando o objetivo é o de figurar os dados estatísticos diretamente relacionados com áreas geográficas ou políticas.

PICTOGRAMA

O pictograma constitui um dos processos gráficos que melhor fala ao público, pela sua forma ao mesmo tempo atraente e sugestiva. A representação gráfica consta de figuras.

Exemplo 3.13: Pictograma

Fonte: *Folha de S. Paulo*, 18/7/2000

CAPÍTULO 4
ANÁLISE DE PEQUENOS CONJUNTOS DE DADOS

INTRODUÇÃO

A análise de dados frequentemente segue linhas diferentes, conforme se trate de um grande ou de um pequeno conjunto de dados. Quando há uma pequena quantidade de dados, utilizam-se os métodos que seguem neste capítulo. Para maior quantidade de dados, são mais práticos métodos que exigem primeiro o agrupamento dos dados. Essas técnicas serão consideradas posteriormente.

Frequentemente, um conjunto de números pode reduzir-se a uma ou a algumas medidas numéricas que resumem todo o conjunto. Tais medidas são de mais fácil manejo e compreensão do que os dados originais.

O objetivo aqui é apresentar os métodos mais úteis para resumir dados. Embora não exista um padrão que se possa considerar o melhor, há técnicas que se prestam melhor que outras a determinadas situações.

MEDIDAS DE TENDÊNCIA CENTRAL

Há situações em que não estamos interessados nos padrões de um grupo, mas em caracterizá-lo como um todo. Podemos ter questões como: Qual o salário médio do trabalhador brasileiro? Qual o tipo sanguíneo mais comum? Qual a nota que divide os alunos de uma turma em um grupo superior e o outro inferior? Para responder a essas questões necessitamos de um grupo único, que represente todos os valores obtidos pelo grupo. Este número possibilita a caracterização do grupo como um conjunto e tende a se condensar no centro da série; desse fato deriva o termo "*medida de tendência central*". A utilização de medidas de posição não substitui o uso de tabelas e de gráficos.

Veremos, então, três medidas de tendência central: a *média*, a *mediana* e a *moda*. Elas constituem maneiras diversas de determinar um único número representativo de uma série, e, conforme veremos, raramente coincidem.

1) MÉDIAS

A média de um conjunto de números é um valor que, levando em conta a totalidade dos elementos do conjunto, pode substituir a todos sem alterar determinada característica desse conjunto.

Por exemplo, se a característica do conjunto é a soma dos seus elementos, tem-se a mais simples de todas as médias: *a média aritmética.*

Existem vários tipos de médias, sendo a mais utilizada a aritmética; portanto, sempre que mencionarmos simplesmente média, estaremos nos referindo à aritmética.

MÉDIA ARITMÉTICA (μ ou $\bar{x}$)

A média (aritmética) é, de modo geral, a mais importante de todas as mensurações numéricas descritivas. Consiste em adicionar os elementos e dividir a soma pelo número de elementos adicionados. A média é representada, por convenção, por $\bar{x}$ (lê-se x barra) quando estamos lidando com uma amostra ou μ quando o conjunto de dados for uma população .

Em notação de somatório, a média aritmética é representada da seguinte forma:

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n} \quad \text{ou} \quad \mu = \frac{\sum_{i=1}^{N} x_i}{N}$$

ou mais simples como:

$$\bar{x} = \frac{\sum x_i}{n} \quad \text{ou} \quad \mu = \frac{\sum x_i}{N}$$

onde:

$\bar{x}$ é a média aritmética amostral
μ é a média aritmética populacional
x_i são os valores da variável
Σ (letra Sigma) é o somatório dos valores da variável
n é o número de medidas efetuadas na amostra
N é o número de medidas efetuadas na população

Quando desejamos saber a média dos dados determinamos a média aritmética simples.

Exemplo 4.1: Sabendo-se que o número de peças produzidas por sete máquinas diferentes, num certo dia, foi 10, 17, 13, 15, 16, 18 e 12, temos, para produção média desse dia:

$$\bar{x} = \frac{10+17+13+15+16+18+12}{7} = \frac{101}{7} = 14{,}4$$

Logo:

$\bar{x}$ = 14,4 peças

A média aritmética de uma amostra pode não pertencer ao conjunto original de valores, nem precisa ter significado real.

Média aritmética ponderada ($\bar{x}$)

A fórmula anterior para calcular a média aritmética supõe que cada observação tenha a mesma importância. Embora este seja o caso mais geral, há exceções.

A média aritmética ponderada é aquela resultante de um conjunto de valores, no qual alguns valores têm importância (ou quantidade de ocorrências) maior que a dos outros.

Exemplo 4.2: *O IBGE vai rever o cálculo do índice de inflação (INPC) para que retrate com mais fidelidade o custo de vida... O setor de vestuário, com* ***peso*** *de 10% na formação do índice, deve ficar com uma* ***ponderação*** *entre 5% e 6%* .

Exemplo 4.3: Se o exame final, em um curso, tem peso 3 e as provas realizadas no semestre têm peso 1, e um aluno tem notas 85 no exame, 70 e 90 nas provas, sua **média** (**aritmética ponderada**) será:

$$\bar{x} = \frac{3x85+1x70+1x90}{1+1+3} = \frac{255+70+90}{5} = \frac{415}{5} = 83$$

Podemos, então, escrever:

$$\boxed{\bar{x} = \frac{\sum x_i . w_i}{\sum w_i}}$$

onde w_i são os pesos da observação de ordem *i* .

Exemplo 4.4: Os salários médios mensais dos professores de ensino fundamental em três cidades são R$ 1.450,00, R$ 1.620,00 e R$ 1.190. Havendo 720, 660 e 520 professores de ensino elementar nessas cidades, seu salário médio será:

Exemplo 4.5: Uma pesquisa amostral efetuada junto a estudantes de uma faculdade acusa os seguintes dados sobre o conceito obtido na disciplina de Estatística.

Conceito	Número de estudantes
0	4
1	28
2	41
3	29
4	12
Total	

Baseados na tabela, podemos afirmar que o conceito médio é:

MÉDIA GEOMÉTRICA

A média geométrica de uma amostra é um número que, levando em conta o total dos elementos dessa amostra, pode representar a todos, sem alterar o produto desses elementos. Assim sendo, a média geométrica de uma amostra de tamanho *n* é igual à raiz de ordem *n* do produto dos *n* valores.

Desse modo, a média geométrica é calcula por:

$$\bar{x}_G = \sqrt[n]{x_1.x_2. \dots .x_n} \qquad \text{ou} \qquad \bar{x}_G = \sqrt[n]{\Pi x_i}$$

Ao contrário da média aritmética, a média geométrica não é muito influenciada pelos valores extremos de uma sequência numérica. Ainda, a média geométrica é definida apenas para números positivos.

A média geométrica é usada para médias proporcionais de crescimento quando uma medida subsequente depende de medidas prévias.

Se uma população de 2 milhões de habitantes em 1960 aumentou para 8 milhões em 1980, quadruplicou em 20 anos; qual teria sido a cifra da população em 1970? Não teria sido cinco milhões, que é a média aritmética de 2 e 8 milhões, pois o aumento é mais rápido nos anos posteriores do que nos anteriores. A cifra real é determinada calculando-se a média geométrica, sendo multiplicados todos os valores da série e em seguida extraída a raiz de ordem n desses valores, de acordo com seguinte :

Para o nosso exemplo teríamos

$\bar{x}_G = \sqrt[2]{\mathbf{2} x \mathbf{8}} = \mathbf{4}$ ou seja, 4 milhões de pessoas em 1970.

Comparemos as duas situações a seguir:

1ª) As importações brasileiras durante o ano de 1998 foram as seguintes, em bilhões de dólares: janeiro, 4.577; fevereiro, 3.799; março, 5.038; abril, 4.799; maio, 4.913; junho, 4.844; julho, 5.329; agosto, 4.634; setembro, 5.338; outubro, 5.039; novembro, 4.709 e dezembro, 4.538. Determine a média das importações brasileiras em 1998.

2ª) O crescimento do Brasil foi de 2,8% em 1996, 3,7% em 1997 e 0,5% em 1998. Determine a taxa média de crescimento do Brasil nesses três anos.

Na primeira situação, bastaria calcular a média aritmética simples dos valores dos 12 meses. Isso resultaria U$ 4.794,75 bilhões.

Na segunda situação devemos calcular a média geométrica desses três valores:

$$\bar{x}_G = \sqrt[3]{2{,}8 \, x \, 3{,}7 \, x \, 0{,}5} = 1{,}7302\%$$

Média geométrica ponderada

$$\bar{x}_G = \sqrt[\sum p_i]{x_1^{p_1} \cdot x_2^{p_2} \ldots x_n^{p_n}}$$

MÉDIA HARMÔNICA

Já vimos que a média aritmética não é adequada para todas as séries de dados. Não pode ser empregada, por exemplo, para médias de crescimento (usamos a média geométrica) ou proporções de velocidade. Digamos que um motorista dirija seu carro de uma cidade A para uma cidade B a uma velocidade média de 60 quilômetros por hora. Na volta, ou seja, a viagem da cidade B para a cidade A ele perfaz com uma velocidade média de 30 quilômetros por hora. Qual a velocidade média global? A resposta não é 45 quilômetros por hora.

Vamos supor que a distância de A até B seja de 60 km (embora possa ser considerada qualquer distância). Então:

- o tempo para deslocar-se de B até A $= \dfrac{60\,km}{30\,km/h} = 2\,horas$
- o tempo de A para B $= \dfrac{60\,km}{60\,km/h} = 1\,hora$
- se o tempo total foi 3 horas e a distância total, 120 km, temos que a velocidade média global é 40 km/h

A média acima é harmônica entre 30 e 60. Calculamos assim $\bar{x}_H = \dfrac{2}{\dfrac{1}{30} + \dfrac{1}{60}} = 40$

A fórmula é a seguinte:

$$\bar{x}_H = \frac{n}{\sum \dfrac{1}{x_i}}$$

Exemplo 4.6: Um investidor compra R$ 18.000 em ações de uma companhia a R$ 45,00 a ação. Num segundo momento, compra R$ 18.000 a R$ 36,00 a ação e, por fim, numa terceira aplicação, compra R$ 18.000 a R$ 30,00 a ação. Assim, descubra o preço médio por ação pago pelo investidor.

Média harmônica ponderada

$$\bar{x}_H = \frac{\sum P_i}{\dfrac{p_1}{x_1} + \dfrac{p_2}{x_2} + \ldots \dfrac{p_n}{x_n}} \quad ou \quad \bar{x}_H = \frac{\sum p_i}{\sum \dfrac{p_i}{x_i}}$$

2) MEDIANA (Md)

Analisemos a situação a seguir:

As idades de seis alunos que participaram de uma excursão com finalidade geológica são 18, 19, 20, 17, 19, 18 anos e a idade do professor que foi com eles é 50 anos. Ao determinarmos a idade média das sete pessoas obteremos $\bar{x}$ = 23 anos, mas uma afirmação de que a idade média do grupo é 23 anos pode ser facilmente mal interpretada. Poderíamos inferir incorretamente que todas as pessoas que participaram da excursão estivessem na casa dos 20 anos.

Para evitar a possibilidade de sermos induzidos em erro por uma média afetada por um valor muito pequeno ou muito grande, por vezes é preferível caracterizarmos o centro de um conjunto de dados por outra medida que não a média: por exemplo, a **mediana**, que vamos estudar a seguir.

A mediana é aquele valor que ocupa a posição central da listagem, estando a amostra com seus **valores ordenados** e com todos os valores repetidos também incluídos, individualmente, na lista. A mediana da amostra divide o conjunto total em duas partes iguais, com metade (50%) dos valores acima da mediana da amostra e metade (50%) abaixo dela. A mediana da amostra pode não pertencer ao conjunto original de valores.

Exemplo 4.7: Dada uma série de valores, como, por exemplo: 5, 13, 10, 2, 18, 15, 6, 16, 9, de acordo com a definição de mediana, o primeiro passo a ser dado é o de ordenação (crescente ou decrescente) dos valores:

2 - 5 - 6 - 9 - 10 - 13 - 15 - 16 - 18

Em seguida tomamos aquele valor central que apresenta o mesmo número de elementos à direita e à esquerda. Em nosso exemplo esse valor é o 10.

Logo, Md = 10

Exemplo 4.8: Se a lista de valores tiver número par de termos, a mediana será, por definição, qualquer número compreendido entre os dois valores centrais da série. Convencionaremos utilizar o ponto médio. Dada a lista:

2, 6, 7, 10, 12, 13, 18, 21

tem , para mediana, a média aritmética entre 10 e 12.

Logo:

Md = $\frac{10+12}{2} = \frac{22}{2} = 11$

Md = 11

Então, se os dados da lista estão ordenados e *n* é o número de elementos dessa lista, o valor mediano será:

- o termo de ordem $\frac{n+1}{2}$, se *n* for ímpar
- a média aritmética dos termos de ordem $\frac{n}{2}$ e $\frac{n}{2}+1$ se *n* for par

OBSERVAÇÕES

1) A média e a mediana não têm, necessariamente, o mesmo valor.
2) A mediana não, necessariamente, coincide com um elemento da série.

Exemplo 4.9: Em 15 dias, um laboratório realiza 40, 52, 55, 38, 40, 48, 56, 56, 60, 37, 58, 63, 46, 50 e 61 testes químicos. Qual a mediana para o contexto do problema?

Características da mediana

1) Não depende de todos os valores da série, podendo se manter inalterável com a modificação de alguns deles.

2) Não é influenciada pelos valores extremos da distribuição; por isso é particularmente indicada quando existem dados discrepantes.

3) Pode ser calculada quando os valores mais altos e mais baixos de uma série não podem ser exatamente definidos.

3) MODA(Mo)

A denominação moda torna-se coerente na medida em que é (são) o(s) evento(s) que mais se destaca(m), isto é, que ocorre(m) com maior frequência no fenômeno estudado. Examinemos alguns exemplos do nosso cotidiano:

Exemplo 4.10: Quando queremos informações sobre o tipo de sangue mais comum, estamos interessados na moda. Se um comerciante pretende abrir uma loja de calçados e quer saber quais os números de sapatos femininos que deve encomendar em maior quantidade, a medida de tendência que ele necessita para um bom planejamento administrativo é a moda. Numa eleição, o candidato que tem o maior número de votos representa a moda. Evidentemente, o comerciante pode constatar que não há um único número de sapato que predomine, mas que os mais comuns são 35, 36 e 37. Terá, assim, uma distribuição multimodal, com três modas: 35, 36 e 37.

Cabe ressaltar que, apesar de ser a frequência que se destaca, a moda não representa necessariamente a maioria no total de resultados.

Uma sequência de números pode não ter valor modal (ou moda) ou apresentar vários tipos de repetições, recebendo então várias denominações:

a) **amodal**, quando não tem distinção entre todas as frequências que aparecem;
b) **unimodal** , quando há apenas uma moda;
c) **bimodal**, quando há duas modas;
d) **multimodal**, quando há três ou mais modas.

Exemplo 4.11: Encontre a moda das amostras abaixo:

a) 2, 7, 5, 4, 3, 1

b) 1, 3, 9, 2, 9, 5

c) 7,1 ; 8,4 ; 7,1 ; 7,1 ; 9,5 ; 8,4 ; 9,4 ; 8,4

Observação

Comparada com a média e com a mediana, a moda é a menos útil das medidas para problemas estatísticos, porque não se presta à análise matemática, ao contrário do que ocorre com as outras duas medidas. A utilidade da moda se acentua quando um ou dois valores, ou um grupo de valores, ocorrem com muito maior freqüência que outros.

EXERCÍCIOS

1) Inspecionam-se quinze rádios antes da remessa. Os números de defeitos por unidade são: 1, 0, 3, 4, 2, 1, 0, 3, 1, 2, 0, 1, 1, 0, 1. Determine o número médio, mediano e modal de defeitos.

2) Qual o número que devemos juntar a 5; 7; 8 e 2 de modo que sua média seja 6 ?

3) A média aritmética simples de um conjunto de 10 números é 35. Se o número 12 for retirado do conjunto, qual será a média aritmética dos números restantes?

4) A nota de Estatística de uma turma seria calculada com a média aritmética de 4 testes. Dessa maneira, Luciana obteria nota 7. O professor, no entanto, resolver anular um dos testes no qual ela havia tirado 8. Qual vai ser a nota de Luciana?

5) Se o salário médio anual pago aos três profissionais de uma empresa é R$ 156.000,00, algum deles pode receber um salário anual superior a R$ 500.000,00?

6) Em um posto de controle rodoviário, doze motoristas multados por excesso de velocidade estavam dirigindo a 8 - 11 - 14 - 6 - 8 - 10 - 20 - 11 - 13 - 18 - 9 – 15 quilômetros por hora acima do limite regulamentar de velocidade.
   a) Em média, em quantos quilômetros por hora esses motoristas estavam excedendo o limite?

   b) Se aquele motorista que excedia o limite em menos de 15 quilômetros por hora foi multado em R$ 60,00 e os outros foram multados em R$ 88,00, determine a média das multas que esses motoristas tiveram de pagar.

7) Durante um período de uma hora uma sorveteria recebeu 20 fregueses, e os valores das compras em reais foram:

1,25	2,50	1,25	5,50	3,25	3,75	2,75	6,25	4,00	2,50
1,25	1,25	3,75	6,00	4,50	3,25	1,25	4,50	2,50	1,50

   a) Calcule o valor médio das compras.
   b) Se cada compra abaixo de R$5,00 faz jus a um bônus de 50 centavos, e cada compra de R$5,00 ou mais faz jus a um bônus de 1 real, ache o valor médio desses 20 bônus.

8) O número de carros vendidos por cada um dos 10 vendedores de uma revenda autorizada de automóveis durante certo mês, é 10,10,4,7,2,12,10,12,15 e 14. Determinar:
   a) a venda média;
   b) a venda mediana;
   c) a moda para esta distribuição.

9) O número de acidentes ocorridos durante um dado mês em 13 departamentos de manufaturas de uma indústria foi: 2, 0, 0, 3, 3, 12, 1, 0, 8, 1, 0, 5 e 1. Calcular:
   a) a média;
   b) a mediana;
   c) a moda para o número de acidentes por departamento.

10) Suponha que os preços de varejos de alguns itens selecionados tenham variado conforme a tabela a seguir. Determinar a mudança percentual média nos preços de varejo.

Item	Porcentagem de aumentos	Despesa média mensal (antes do aumento)
Leite	10%	100,00
Carne	-6%	150,00
Vestuário	-8%	150,00
Gasolina	20%	250,00

11) A média pode ser zero? Pode ser negativa? Explique.

12) A mediana pode ser zero? Negativa? Explique.

13) As observações a seguir são relativas à resistência por cisalhamento (em MPa) de uma junta soldada de uma determinada forma:

22,2 40,4 16,4 73,7 36,6 109,9 30,0 4,4 33,1 66,7 81,5

a) Qual o valor da média amostral?
b) Qual o valor da mediana amostral? Por que esse valor é tão diferente da média?
c) Calcule a média aparada, excluindo a menor e a maior observação.

RESPOSTAS:

1) $\bar{x}$ = 1,33, Md = 1, Mo = 1

2) 8

3) 37,56

4) 6,7

5) Não

6) a) 11,92 b) 67

7) a) 3,14 b) 0,58

8) a) $\bar{x}$ = 9,6 b) Md = 10 c) Mo = 10

9) a) $\bar{x}$ = 2,77 b) Md = 1 c) Mo = 0

10) 6%

11) Sim. Sim.

12) Sim. Sim.

13) a) 46,8 b) 36,6 c) 44,5

SEPARATRIZES

A mediana é apenas um dentre os muitos ***quantis*** que dividem os dados em duas ou mais partes tão aproximadamente iguais quanto possível. Entre eles, destacam-se os *quartis*, os *decis* e os *percentis*, que dividem os dados em 4, 10 e 100 partes, respectivamente.

QUARTIS

Vamos nos ocupar principalmente da análise preliminar de conjuntos relativamente pequenos de dados. É o problema de dividir esses dados em quatro partes aproximadamente iguais, onde dizemos "aproximadamente iguais" porque não há maneira de dividir em quatro partes iguais um conjunto com n = 27 ou n = 33, por exemplo. As medidas estatísticas criadas com esta finalidade são tradicionalmente conhecidas como *quartis*, Q_1, Q_2 e Q_3. Sem dúvida, Q_2 é simplesmente a mediana. Por outro lado, há vasto campo para arbitrariedades na definição do *quartil inferior* Q_1 e do *quartil superior* Q_3.

Exemplo 4.12: Consideremos as seguintes temperaturas registradas em 12 cidades em um dia de junho, medidas em graus Celsius:

30 15 26 17 25 12 18 19 34 22 14 33

Ordenando estes valores do menor para o maior, temos:

Calculemos:

Q_1 = Q_2 = Q_3 =

Tudo funcionou bem neste exemplo porque 12, o tamanho da amostra, é múltiplo de 4. Que devemos fazer, entretanto, se isto não ocorrer? Suponha, por exemplo, que a cidade com a temperatura de 17 deixasse de reportar o valor; ficaríamos com os 11 números abaixo, dispostos ordenadamente:

Calculemos:

Q_1 = Q_2 = Q_3 =

PERCENTIS

É o problema de dividir esses dados em cem partes aproximadamente iguais, onde dizemos "aproximadamente iguais" porque não há maneira de dividir em cem partes iguais um conjunto com *n*=328, por exemplo. As medidas estatísticas criadas com esta finalidade são tradicionalmente conhecidas como *percentis*, P_1, P_2 , ... P_{81}, ... , P_{98} e P_{99}.

MEDIDAS DE DISPERSÃO

DISPERSÃO OU VARIABILIDADE

Vimos anteriormente que um conjunto de valores pode ser convenientemente sintetizado, por meio de procedimentos matemáticos, em poucos valores representativos - média aritmética , mediana, moda. Tais valores podem servir de comparação para dar a posição de qualquer elemento do conjunto. Porém, não é o bastante dar uma das medidas de posição para caracterizar perfeitamente um conjunto de valores.

Exemplo 4.13: Suponhamos que se deseja comparar o desempenho de dois funcionários, com base no número de cadeiras sem defeitos produzidas durante uma semana:

Empregado A: 80, 81, 79, 80, 80 $\rightarrow \bar{x} = \mathbf{80}$ cadeiras
Empregado B: 70, 90, 80, 72, 93 $\rightarrow \bar{x} = \mathbf{81}$ cadeiras

Baseados nestes únicos resultados obtidos, diríamos que a produção de B é melhor do que de A, já que B produz, em média, um maior número de cadeiras diariamente. No entanto se formos um

pouco cuidadosos, percebemos que a produção de A varia de 79 a 81 cadeiras, ao passo que a de B varia de 70 a 93 cadeiras, o que indica que o desempenho de A é bem mais **homogêneo** do que de B.

É evidente que um alto grau de homogeneidade costuma ser considerado como uma qualidade desejável nesta situação.

Consideremos agora a seguinte situação:

Exemplo 4.14: Temos duas turmas A e B . Observe a tabela onde é mostrado o desempenho dos alunos. Calcule a média de cada turma.

Turma A	Turma B
4	1
6	0
5	10
3	9
4	2
7	8
6	5
$\sum = 35$	$\sum = 35$

Esses dois conjuntos possuem a mesma média. Pode-se dizer que estes conjuntos são iguais?

Não, porque embora ambos tenham a mesma média eles diferem na sua homogeneidade. Neste exemplo, o conjunto B é mais **heterogêneo** ou **mais disperso** que o conjunto A. Portanto, não bastam que conheçamos apenas a média de um conjunto, precisamos também, conhecer a dispersão do conjunto.

Daí surgem as medidas de variabilidade ou medidas de dispersão. Estas medidas medem a dispersão do conjunto, avaliando a heterogeneidade ou a homogeneidade do mesmo.

A dispersão mede quão próximos uns dos outros estão os valores de um grupo.

AMPLITUDE

A amplitude (ou intervalo total) de um conjunto de dados é igual à diferença entre o maior e o menor valor.

Exemplo 4.15: Em um hospital, onde se mede a pulsação de cada paciente três vezes por dia, o paciente A acusou as taxas de 72, 76 e 74, e o paciente B acusou 72, 91 e 59. A taxa média de ambos é a mesma, 74; observe, entretanto, a diferença na variabilidade. Enquanto a pulsação de A é estável, a de B apresenta grande flutuação.

A vantagem de usar a amplitude como medida de dispersão reside no fato de o intervalo ser relativamente fácil de calcular, mesmo para um grande conjunto de números. Entretanto, a maior limitação da amplitude é o fato dela levar em conta somente os dois valores extremos de um conjunto, nada informando quanto aos outros valores.

VARIÂNCIA

A variância é a medida de dispersão que mede a média dos quadrados dos desvios dos valores, de um conjunto numérico em relação a sua média.

Cálculo da Variância:

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n-1}$$ amostral

$$\sigma^2 = \frac{\sum (x_i - \mu)^2}{N}$$ populacional

Onde:

x_i = valor da variável
$\bar{x} =$ média amostral
$x_i - \bar{x}$ = desvio em relação à média
μ = média populacional

No cálculo de variância divide-se a soma obtida por *n-1* quando se trata de um conjunto de números que representam uma amostra. Se um conjunto de números constitui uma população, ou se a finalidade de somar os dados é apenas descrevê-los, e não fazer inferências sobre uma população, então deve-se usar *N* em lugar de *(n-1)* no denominador.

Exemplo 4.16: Calcular a variância da produção dos dois funcionários.

Funcionário A	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	Funcionário B	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
80			70		
81			90		
79			80		
80			72		
80			93		
	∑ =	∑ =		∑ =	∑ =

Exemplo 4.17: Calcule a variância da tabela a seguir.

Turma A	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	Turma B	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
4			1		
6			0		
5			10		
3			9		
4			2		
7			8		
6			5		
	∑ =	∑ =		∑ =	∑ =

A variância é expressa na unidade de medida do conjunto numérico. Como ela é um valor **ao quadrado**, torna-se difícil a interpretação prática, motivo pelo qual surge outra medida de dispersão o desvio padrão.

DESVIO PADRÃO

O desvio padrão é simplesmente a raiz quadrada positiva da variância.

$$s = \sqrt{s^2} \qquad \sigma = \sqrt{\sigma^2}$$

ou

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n-1}} \qquad \sigma = \sqrt{\frac{\sum (x_i - \mu)^2}{N}}$$

Exemplo 4.18: Calcular o desvio padrão das tabelas anteriores.

O desvio padrão é uma das medidas mais comumente usadas para distribuições, e desempenha papel relevante em toda a estatística. Cabe notar que a unidade do desvio padrão é a mesma da média. Por exemplo, se a média é em reais, o desvio padrão também se exprime em reais. A variância, por sua vez, se exprime em quadrados de unidades (p. ex., reais^2).

Fórmula alternativa para o cálculo de variância e desvio padrão:

$$s^2 = \frac{\sum x^2 - \frac{\left(\sum x\right)^2}{n}}{n-1} \quad \text{e} \quad s = \sqrt{\frac{\sum x^2 - \frac{\left(\sum x\right)^2}{n}}{n-1}}$$

COEFICIENTE DE VARIAÇÃO

Examinemos o seguinte exemplo, em que são comparados os pesos de dois grupos de indivíduos (crianças e adultos), apresentados na tabela 4 abaixo:

Crianças (kg)	Adultos (kg)
4	66
2	64
6	62

Verificamos que o peso médio para as crianças é de 4 kg, enquanto para os adultos é de 64 kg. A dispersão dos dados em torno da média é a mesma, pois ambos têm desvio padrão s = 2 kg. Entretanto a variação de 2 kg no grupo de crianças, cujo peso médio é de 4 kg, é mais importante do que a mesma variação no grupo de adultos, cujo peso médio é 64 kg. Neste tipo de situação, é mais interessante o emprego de uma medida de dispersão relativa adimensional e geralmente expressa em porcentagens: o coeficiente de variação.

O coeficiente de variação é dado pelo quociente entre o desvio padrão e a média de um conjunto.

$$CV = \frac{s}{\bar{x}} x100 \qquad \text{ou} \qquad CV = \frac{\sigma}{\mu} x\,100$$

Exemplo 4.19: Determinar os coeficientes de variação da tabela anterior.

AMPLITUDE INTERQUARTÍLICA

É definida como a amplitude do intervalo entre o primeiro e o terceiro quartis, ou seja:

$$Q = Q_3 - Q_1$$

A amplitude interquartílica é uma medida de variabilidade bastante robusta, que é pouco afetada pela presença de dados atípicos, onde 50% dos dados estão entre Q_1 e Q_3.

EXERCÍCIOS

1) O desvio padrão pode ser zero? Explique.

2) Calcule a média e o desvio padrão de uma amostra das vendas diárias, em reais;
8 100; 9 000; 4 580; 5 600; 7 680; 4 800 e 10 640

3) Em um exame final de Matemática, o grau médio de um grupo de 150 alunos foi 7,8 e o desvio padrão, 0,80. Em Estatística, entretanto, o grau médio final foi 7,3 e o desvio padrão, 0,76. Em que disciplina foi maior a dispersão?

4) Uma distribuição apresenta as seguintes estatísticas: s = 1,5 e CV = 2,9%. Determine a média da distribuição.

5) Sabendo que um conjunto de dados apresenta para média aritmética e para desvio padrão, respectivamente, 18,3 e 1,47, calcule o coeficiente de variação.

6) Calcular a variância e o desvio padrão abaixo correspondente ao peso de um grupo de alunos (amostra).

Aluno	Peso (kg)
A	53,2
B	42,7
C	48,8
D	55,0
E	31,5
F	44,2
G	45,6
H	49,1
I	54,0
J	56,2
K	38,8
L	37,4
Total	

7) Medidas as estaturas de 1.017 indivíduos, obtivemos $\bar{x}$ = 162,2 cm e s = 8,01 cm. O peso médio desses mesmos indivíduos é 52kg, com um desvio padrão de 2,3kg. Esses indivíduos apresentam maior variabilidade em estatura ou em peso?

8) Um grupo de 85 moças tem estatura média de 160,6 cm, com um desvio padrão igual a 5,97cm. Outro grupo de 125 moças tem uma estatura média de 161,9 cm, sendo o desvio padrão igual a 6,01cm. Qual é o coeficiente de variação de cada um dos grupos? Qual o grupo mais homogêneo?

9) Um grupo de cem estudantes tem uma estatura média de 163,8 cm, com um coeficiente de variação de 3,3%. Qual o desvio padrão desse grupo?

10) Quinze amostras de ar de certa região foram obtidas e para cada uma delas foi determinada a concentração de monóxido de carbono. Os resultados (em ppm) foram:

9,3	10,7	8,5	9,6	12,2	15,6	9,2	10,5
9,0	13,2	11,0	8,8	13,7	12,1	9,8	

Determinar a concentração média de monóxido de carbono, a concentração mediana e o desvio padrão para as 15 amostras.

RESPOSTAS

1) Sim. 2) $\bar{x}$ = 7200 s = 2284

3) CV em Matemática = 10,3 e CV em Estatística = 10,4%

4) 51,7 5) 8%

6) s^2 = 60,6 s = 7,8 (para média = 46,4)

7) CV em estatura = 4,9% CV em peso = 4,4%

8) CV primeiro grupo = 3,72% CV segundo grupo = 3,71% 5,4

9) s = 2,08 10) $\bar{x}$ =10,88 Md=10,5