INTRODUÇÃO À INFERÊNCIA ESTATÍSTICA

Aula 24/07/2023

Índice

Revisão da aula anterior

Inferência estatística

- Introdução
- Exemplos
- Inferência
- Como selecionar uma amostra

Revisão da aula anterior

Modelo normal

$$f(x) = \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Modelo normal

$$z = \frac{x-\mu}{\sigma}$$

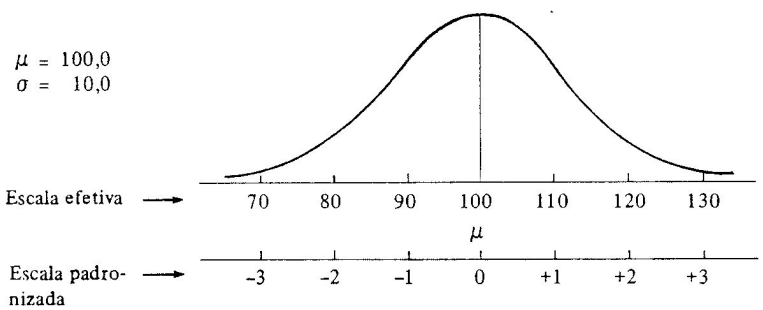

Modelo exponencial

$$f(t;\beta) = \begin{cases} \frac{1}{\beta} e^{-t/\beta}, & se\ t \geq 0 \\ 0, & \text{se } t < 0 \end{cases}$$

$E(T) = \beta$

$Var(T) = \beta^2$

Introdução

- Já estudamos como resumir descritivamente variáveis associadas a um ou mais conjuntos de dados.
- Construímos modelos teóricos (probabilísticos), identificados por parâmetros, capazes de representar adequadamente os comportamentos de algumas variáveis.
- O uso de informações de uma amostra para concluir sobre o todo, faz parte da vida diária da maioria das pessoas.

O que já estudamos

Nas aulas anteriores, tomamos conhecimentos de alguns modelos probabilísticos que procuram medir a variabilidade de fenômenos casuais de acordo com as suas ocorrências: as distribuições de probabilidades de variáveis aleatórias (qualitativas ou quantitativas).

Exemplos: A altura dos brasileiros adultos representa um modelo normal, mas ainda precisamos dos parâmetros de média e variância para vincular a qual modelo normal em que se encaixa.

População

x

Amostra

População

Definição: população é o conjunto de todos os elementos ou resultados sob investigação.

Amostra

Definição: amostra é qualquer subconjunto da população.

Exemplo de situações

- Uma pesquisa para estudar os salários dos 500 funcionários de uma empresa. Seleciona-se uma amostra com 36 indivíduos e anotam-se seus salários.
- Estudo sobre as proporção de indivíduos em uma cidade que são favoráveis a certo projeto governamental. Uma amostra de 200 indivíduos é sorteada, a opinião de cada um é registrada como sendo a favor ou contra o projeto.
- A investigação sobre a duração de um novo tipo de lâmpada. Por exemplo, 100 lâmpadas são deixadas acesas até queimarem.

Exemplo de situações

- O peso real de pacotes de café enchidos automaticamente por uma máquina. A população são todos os pacotes enchidos pela máquina, a mostra pode ser formada 100 pacotes selecionados.
- Um experimento para investigar a “honestidade” de uma moeda, lançamos 50 vezes e observamos o número de caras obtidas.
- Tempo de reação de certo estímulo visual e idade do indivíduo. Pode-se selecionar 20 indivíduos, 10 homens e 10 mulheres com faixas etárias diferentes.

Inferência

O objetivo da Inferência Estatística é produzir afirmações sobre dada característica da população, na qual estamos interessados, a partir de informações colhidas de uma parte da população.

Normalmente, é difícil ter informações sobre toda a população, mas é fundamental descrever qual a população a qual estamos estudando.

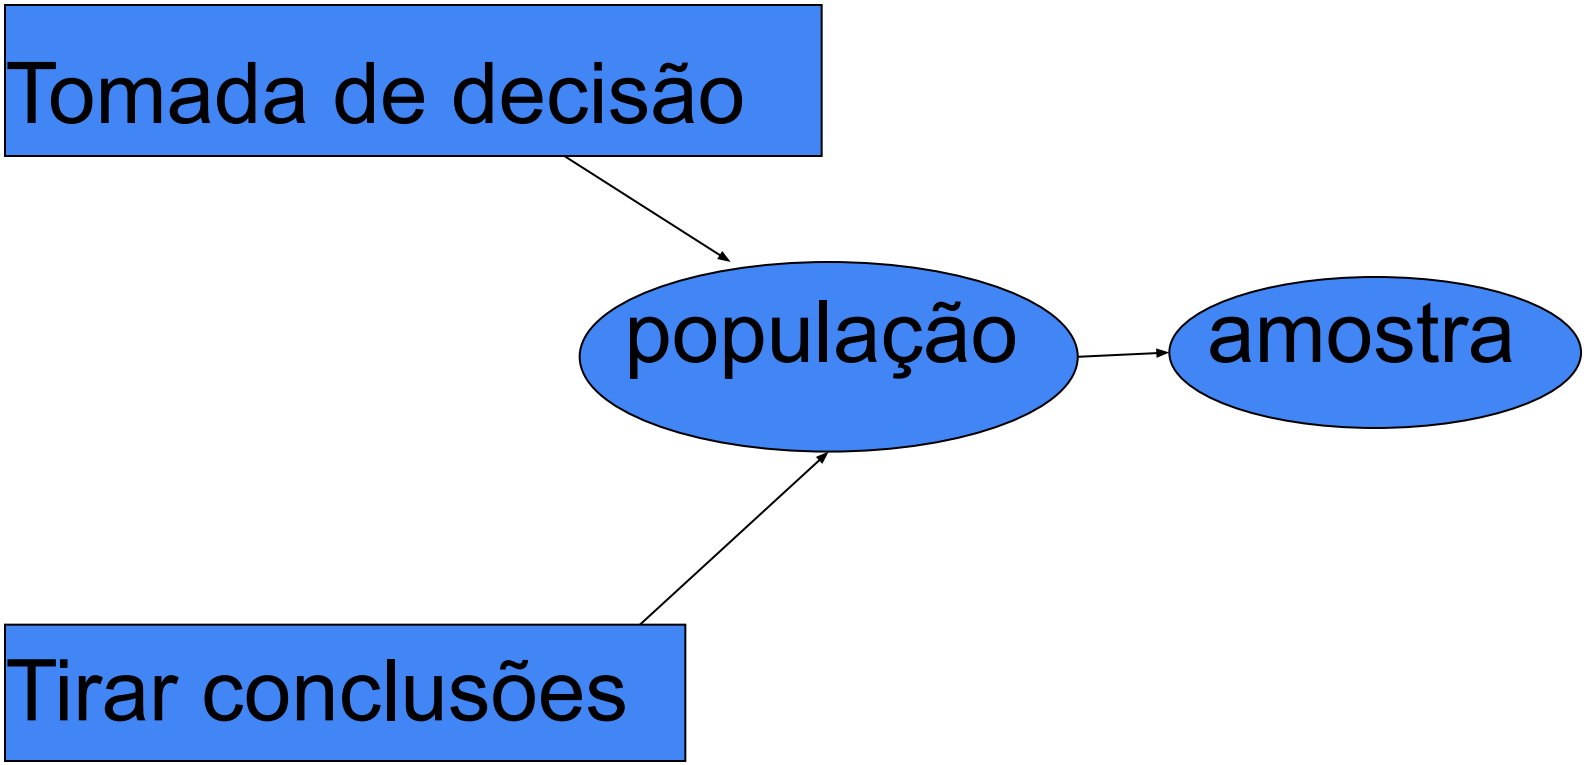
Tomada de decisão
população
amostra
Tirar conclusões

Estimação de parâmetros

Inferência estatística

Teste de hipóteses

Como um exemplo de um problema de estimação de parâmetros:

Suponha que um engenheiro de estruturas esteja analisando a resistência à tensão de um componente usado em um chassi de automóvel.

Uma vez que a variabilidade da resistência à tração está naturalmente presente entre componentes individuais, devido às diferenças nas bateladas da matéria-prima nos processos de fabricação e nos procedimentos de medidas (por exemplo), o engenheiro está interessado na estimação da resistência média à tração dos componentes.

Na prática, o engenheiro usará dados da amostra para calcular um número que é, de algum modo, um valor razoável (ou tentativa) da média verdadeira. Esse número é chamado de **estimativa**. Veremos que é possível estabelecer a precisão da estimativa.

Considere agora uma situação em que duas temperaturas diferentes de reação, como t_1 e t_2, possam ser usadas em um processo químico.

O engenheiro conjectura que t_1 resulta em rendimentos maiores que t_2.

O teste estatístico de hipóteses é a estrutura para resolver problemas desse tipo.

Nesse caso, a hipótese seria que o rendimento médio usando a temperatura t_1 é maior que o rendimento usando a temperatura t_2.

Não há ênfase na estimação de rendimentos; em vez disso, o foco está na tirada de conclusões acerca de uma hipótese estabelecida.

Como selecionar uma amostra

A maneira de obter uma amostra é importante.

Existem tantos modos de fazer que isso é uma especialidade dentro da estatística (Amostragem e Planejamento de Experimentos).

Podemos dividir os procedimentos científicos de obtenção de dados amostrais em três grandes grupos:

- Levantamentos amostrais
- Planejamento de experimentos
- Levantamentos observacionais

Levantamentos amostrais

A amostra é obtida de uma população bem definida, por meio de processos bem protocolados e controlados pelo pesquisador. Podemos subdividir em dois grupos: levantamentos probabilísticos e não probabilísticos.

O primeiro reúne todas as técnicas que usam mecanismos aleatórios de seleção de elementos de uma amostra, atribuindo a cada um deles uma probabilidade, conhecida a priori, de pertencer a amostra.

No segundo grupo estão os demais procedimentos, tais como; amostras intencionais, nas quais os elementos são selecionados com a ajuda de um especialista, e amostra de voluntários, como ocorre em alguns teste sobre novos medicamentos e vacinas.

Planejamento de Experimentos

O principal objetivo é o de analisar o efeito de uma variável sobre outra. Requer, portanto, inferências do pesquisador sobre o ambiente em estudo (população), bem como o controle sobre fatores externos, com o intuito de medir o efeito desejado. Exemplo: como altura de um produto na gôndola de um supermercado pode afetar as vendas, ensaios clínicos em medicina.

Levantamentos observacionais

Nesse caso os dados observacionais são coletados sem que o pesquisador tenha controle sobre as informações obtidas, exceto eventualmente sobre possíveis erros grosseiros.

Nos livros se concentra mais em levantamentos amostrais e num caso simples de amostragem probabilística, a amostragem aleatória simples com reposição, designada por AAS.

Exercícios

Dê a sua opinião sobre os tipos de problemas que surgiram nos seguintes planos amostrais:

1) Para investigar a proporção dos operários de uma fábrica favoráveis à mudança do início das atividades das 7h para as 7h30, decidiu-se entrevistar os 30 primeiros operários que chegassem na fábrica na quarta-feira.
2) Mesmo procedimento, porém o objetivo é estimar a altura média dos operários.
3) Para estimar a porcentagem média da receita municipal investida em lazer, enviaram-se questionários a todas prefeituras, e a amostra foi formada pelas prefeituras que enviaram as respostas.
4) Para verificar o fato de oferecer brindes nas vendas de sabão em pó, tomaram-se quatro supermercados na zona sul e quatro na zona norte de uma cidade. Nas quatro lojas da zona sul, o produto era vendido com brinde, enquanto nas outras quatro lojas era vendido sem brinde. No fim do mês, compararam-se as vendas da zona sul com as da zona norte.

DISTRIBUIÇÃO AMOSTRAL DAS MÉDIAS

Valores de medidas estatísticas, tais como a média, o desvio padrão e as proporções não são necessariamente iguais aos de outras amostras obtidas de uma mesma população. Essa variação é atribuída a diferenças na composição das amostras aleatórias e é conhecida como *variação amostral*. A partir do estudo da variabilidade do resultado, de amostra para amostra, é possível construir distribuições de frequências (distribuições amostrais) que é a base para a inferência estatística.

Dada uma população de valores *x* com distribuição normal, com média μ e desvio padrão σ e dela extraindo-se um grande número de amostras casuais simples de mesmo tamanho *n*, o cálculo das médias dessas amostras leva a valores para diferentes entre si. Essas séries de médias resultantes poderão ser classificadas numa tabela de frequências e representadas por um histograma. Repetindo-se a amostragem indefinidamente, o histograma tenderá para uma curva que representa a distribuição estatística das médias amostrais denominada *distribuição amostral das médias (DAM)*.

Média das amostras

Obtenção da média das médias	
Amostras	Médias
Amostra 1	$\bar{x}_1$
Amostra 2	$\bar{x}_2$
Amostra 3	$\bar{x}_3$
...	...
Amostra m	$\bar{x}_m$
Média das amostras	$\mu_{\bar{x}} = \sum \bar{x}_m / m$

As propriedades dessas distribuições teóricas conferem um papel importante no processo de inferência estatística. A partir dessa distribuição, é possível calcular a média e o desvio padrão da DAM e verificar como estes valores se relacionam com os parâmetros da população.

Vamos usar um conjunto de dados para verificar empiricamente a situação descrita anteriormente. Dados os valores 3, 4, 5 e 8, calcular:

- A média populacional μ.
- As médias de todas as amostras possíveis de 2 elementos, com reposição.
- A média das médias amostrais .

TEOREMA CENTRAL DO LIMITE

Pelo Teorema Central do Limite, a distribuição amostral das médias tende para uma distribuição normal com média μ (igual à média da população) e com desvio padrão $\sigma/\sqrt{n}$ (desvio padrão da população dividido pela raiz quadrada do tamanho da amostra).

A partir do Teorema Central do Limite obtém-se:

- A média da distribuição amostral das médias (a média das médias) é igual à média populacional, ou seja, $\mu_x = \mu$.

- O desvio padrão da distribuição amostral das médias é igual ao desvio padrão da população dividido pela raiz quadrada do tamanho da amostra, isto é, , ou seja, é $\sqrt{n}$ vezes menor que a variação existente na população.

- A distribuição amostral das médias aproxima-se de uma distribuição normal. Quando n for grande (n > 30), a forma de distribuição amostral de médias é, aproximadamente, uma curva normal, qualquer que seja a forma de distribuição populacional da qual as médias foram extraídas (normal ou não).

A maior parte das amostras tende a estimar os parâmetros populacionais com boa aproximação. Isto justifica a relativa confiança nas inferências baseadas nos dados de observações obtidas de uma amostra.

A confiança a ser depositada numa amostra, naturalmente cresce com o aumento do tamanho dessa amostra. Outro aspecto a ser relacionado é, quanto menor a variabilidade mais consistente e reprodutível são os resultados obtidos e, portanto, mais correta a inferência.

DESVIO PADRÃO DA MÉDIA (ERRO PADRÃO)

É possível estimar o desvio padrão da distribuição amostral de médias a partir dos dados fornecidos por uma única amostra.

Essa estimativa é conhecida como *erro padrão da média* ou *desvio padrão das médias*. O desvio padrão da distribuição amostral de médias é $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$.

Na prática, raramente é conhecido, no entanto, pode ser estimado a partir do desvio padrão da amostra: $s_{\bar{x}} = \frac{s}{\sqrt{n}}$.

Exemplo: Numa amostra de 9 embalagens, a resistência à tração de cada uma tem os seguintes valores: 90, 86, 78, 90, 98, 90, 82, 76 e 84 psi, apresentando uma média de 86 psi e desvio padrão 6,85 psi. Qual o erro padrão para essa amostra?