Estatística
e
Probabilidade

19/09/2022

CORRELAÇÃO LINEAR SIMPLES

Ao se estudar uma variável o interesse eram as medidas de tendência central, dispersão, assimetria, etc.

Com duas ou mais variáveis além destas medidas individuais também é de interesse conhecer se elas têm algum relacionamento entre si, isto é, se valores altos (baixos) de uma das variáveis implicam em valores altos (ou baixos) da outra variável.

Por exemplo, pode-se verificar se existe associação entre a altura de planta e altura de espiga, dose de fertilizante e produtividade, taxa de infestação de uma doença e a produtividades, etc.

A associação entre duas variáveis pode ser de dois tipos: experimental e correlacional.

Experimental

Exemplo: Aplicar doses de calcário (tratamentos) e observar as diferenças na produtividade de milho.

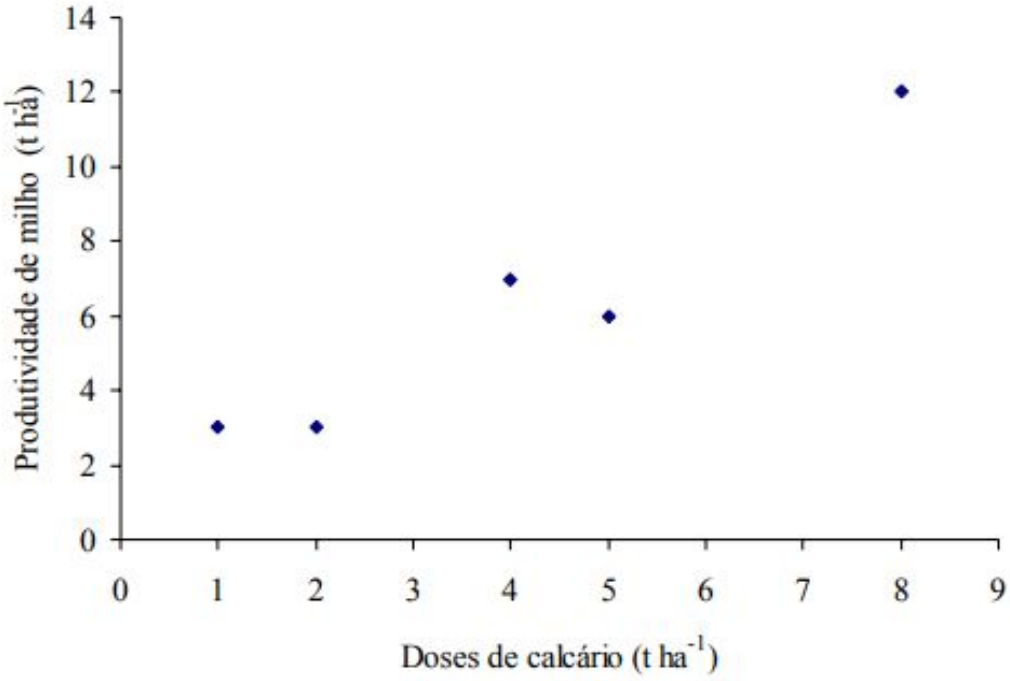

Correlacional

Não se tem nenhum controle sobre as variáveis sendo estudadas. Elas são observadas como ocorrem no ambiente natural, sem nenhuma interferência, isto é, as duas variáveis são aleatórias.

Exemplo: Altura de planta e altura de espiga.

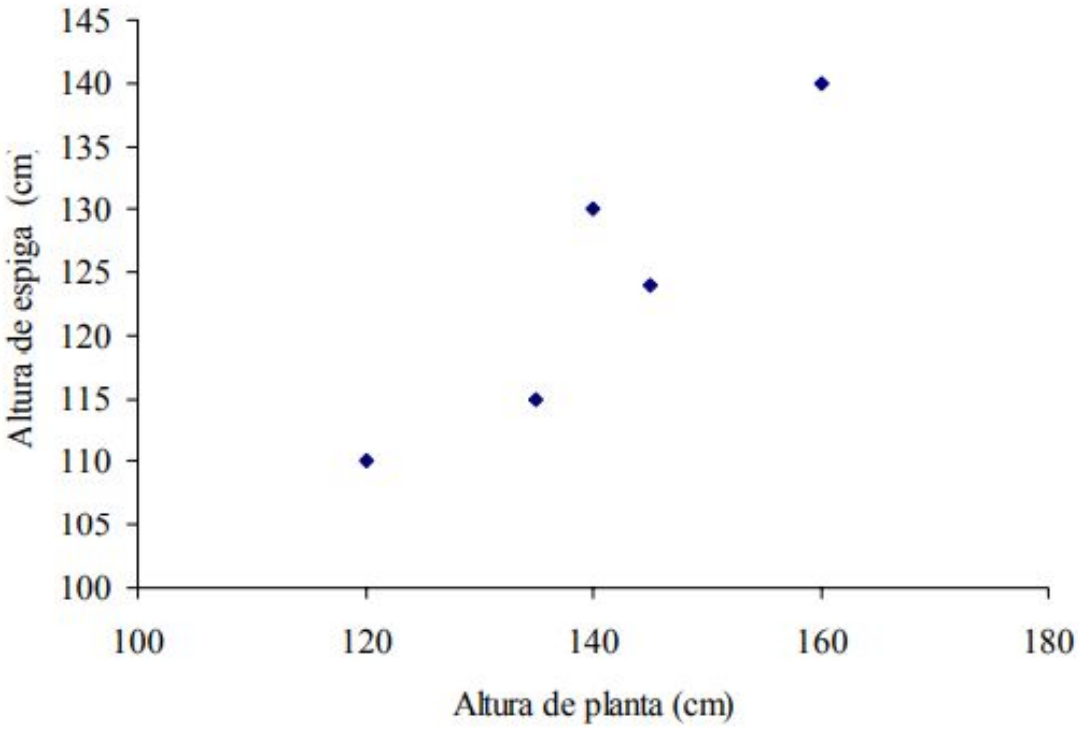

Correlação

Ao estudo do relacionamento entre duas ou mais variáveis denominamos de correlação e regressão.

Se o estudo tratar apenas de duas variáveis tem-se a correlação e a regressão simples, se envolver mais do que duas variáveis, tem-se a correlação e a regressão múltiplas. A regressão e a correlação tratam apenas do relacionamento do tipo linear entre duas variáveis.

A análise de correlação fornece um número que resume o grau de relacionamento linear entre as duas variáveis.

Já a análise de regressão fornece uma equação que descreve o comportamento de uma das variáveis em função do comportamento da outra variável.

PADRÕES DE ASSOCIAÇÃO

Quando não é possível perceber uma relação sistemática entre as variáveis é dito que as variáveis são não correlacionadas, são independentes ou ainda que são ortogonais.

INDICADORES DE ASSOCIAÇÃO

Tabela de contingência 2x2 – dá uma ideia muito superficial da associação entre as variáveis.

Exemplo

Prática de Esportes	Tabagismo		Total
	Presente	Ausente	
Presente	$a = 50$	$b = 15$	$a + b = 65$
Ausente	$c = 10$	$d = 25$	$c + d = 35$
Total	$a + c = 60$	$b + d = 40$	$n = 100$

H_0: não há associação entre tabagismo e prática de esportes

H_A: há associação entre tabagismo e prática de esportes

INDICADORES DE ASSOCIAÇÃO

Diagramas de dispersão – Fornecem uma ideia melhor da associação entre as variáveis. Vamos considerar o seguinte exemplo para o estudar a correlação e regressão linear entre duas variáveis.

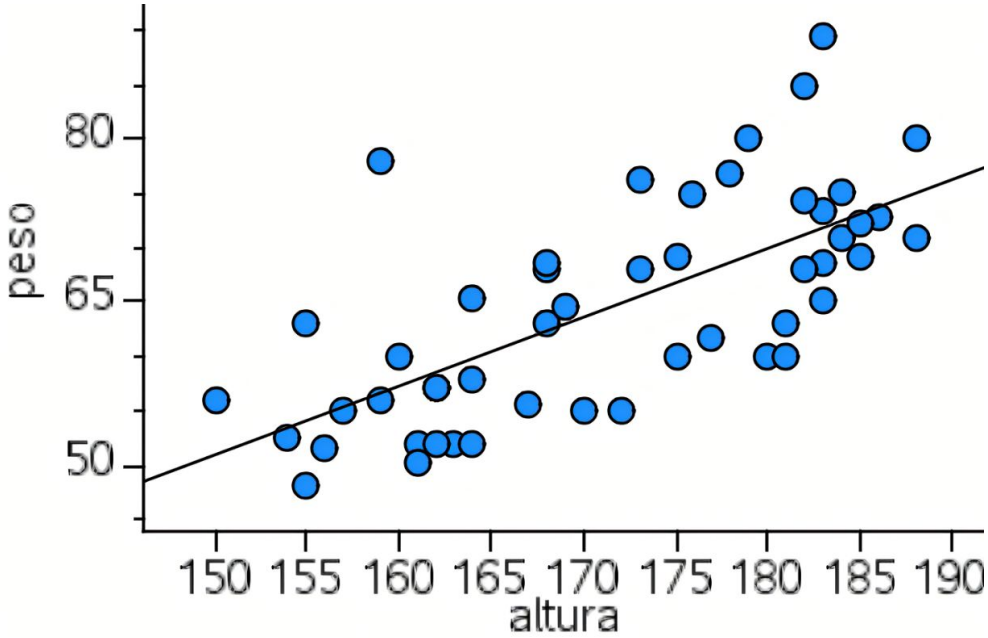

DEFINIÇÃO

Uma medida do grau e do sinal da correlação é dada pela covariância entre as duas variáveis aleatórias X e Y que é uma medida numérica de associação linear existente entre elas, e definida por:

$$r = \frac{n(\sum XY) - (\sum X)(\sum Y)}{\sqrt{n(\sum X^2) - (\sum X)^2}\sqrt{n(\sum Y^2) - (\sum Y)^2}}$$

Exemplo:

Vamos supor que você fez um experimento avaliando o efeito da aplicação de doses de calcário na produtividade de milho. Estou interessado em saber se existe associação linear entre essas variáveis e se posso estimar uma regressão linear entre essas variáveis. Os dados obtidos foram os seguintes:

Tabela 1 – Doses de calcário (t ha^{-1}) e produtividade de milho (t ha^{-1}).

Doses de calcário (t ha^{-1}) (X)	Produtividade de milho (t ha^{-1}) (Y)
1	3
2	3
4	7
5	6
8	12

Para ter uma ideia melhor, as variáveis são colocadas no que é denominado de diagrama de dispersão. Uma das variáveis (X) é representada no eixo horizontal e a outra variável (Y) no eixo vertical, conforme figura 1.

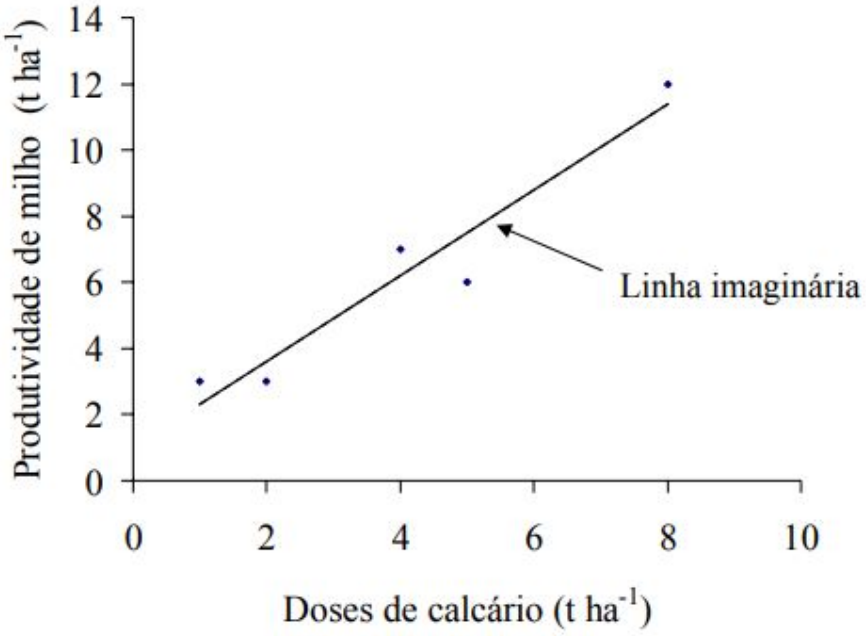

Figura 1 - Diagrama de dispersão das variáveis apresentadas na tabela 1.

Uma olhada rápida no diagrama de dispersão mostra a existência de um relacionamento entre as variáveis, com altos valores de uma das variáveis associados a altos valores da outra variável.

Se não houvesse relacionamento entre elas, os pontos estariam distribuídos ao acaso no gráfico sem mostrarem alguma tendência.

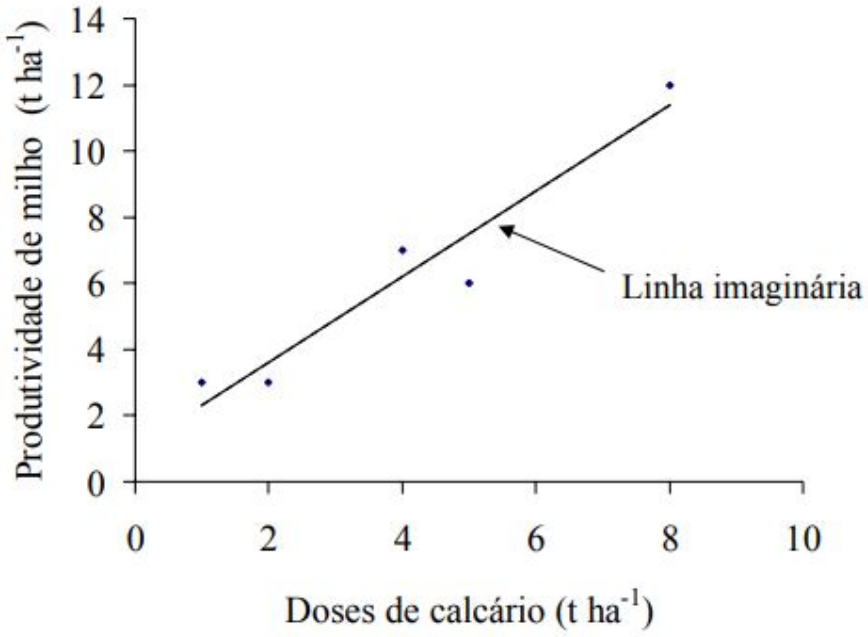

Figura 1 - Diagrama de dispersão das variáveis apresentadas na tabela 1.

O COEFICIENTE DE CORRELAÇÃO LINEAR
ou coeficiente de correlação linear de Pearson

Apesar do diagrama de dispersão nos fornecer uma ideia do tipo e extensão do relacionamento entre duas variáveis X e Y, seria altamente desejável ter um número que medisse esta relação.

Esta medida existe e é denominada de coeficiente de correlação.

- Coeficiente de correlação amostral é indicado pela letra r.
- Coeficiente de correlação populacional é indicado pela letra ρ (rho).

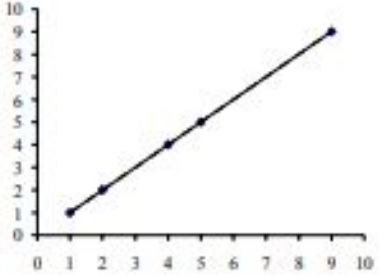

Correlação linear positiva perfeita (r =1)

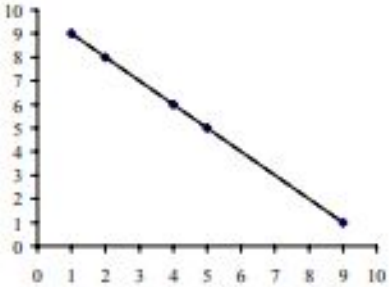

Correlação linear negativa perfeita (r = -1)

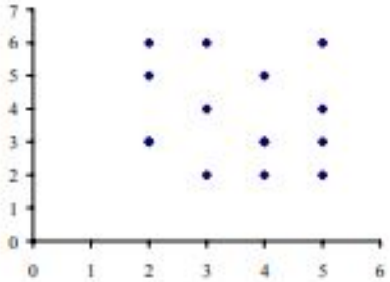

Ausência de relacionamento linear (r = 0)

O coeficiente de correlação rxy linear é um número puro que varia de –1 a +1 e sua interpretação dependerá do valor numérico e do sinal, como segue:

$r_{xy} = -1$	⇨	correlação perfeita negativa
$-1 < r_{xy} < 0$	⇨	correlação negativa
$r_{xy} = 0$	⇨	correlação nula
$0 < r_{xy} < 1$	⇨	correlação positiva
$r_{xy} = 1$	⇨	correlação perfeita positiva
$0{,}2 < r_{xy} < 0{,}4$	⇨	correlação fraca*
$0{,}4 < r_{xy} < 0{,}7$	⇨	correlação moderada*
$0{,}7 < r_{xy} < 0{,}9$	⇨	correlação forte*

*possui o mesmo significado para os casos negativos ou positivos.

HIPÓTESES BÁSICAS

A suposição básica sobre o coeficiente de correlação é que o relacionamento entre as duas variáveis seja linear. Isto é, o coeficiente de correlação é adequado para avaliar somente o relacionamento linear.

Uma segunda hipótese é que as variáveis envolvidas sejam aleatórias e que sejam medidas no mínimo em escala de intervalo. Ele não se aplica a variáveis em escala nominal ou ordinal ou quando uma das variáveis é manipulada experimentalmente, pois neste caso, a escolha dos valores experimentais vai influenciar o valor de r obtido.

Uma terceira hipótese é que as duas variáveis tenham uma distribuição conjunta normal bivariada. Isto é equivalente a dizer que para cada x dado a variável y é normalmente distribuída.

Nosso exemplo

X = Doses de calcário (t ha^{-1})
Y = Produtividade de milho (t ha^{-1})

	X	Y	X^2	Y^2	XY
	1	3	1	9	3
	2	3	4	9	6
	4	7	16	49	28
	5	6	25	36	30
	8	12	64	144	96
somatório	20	31	110	247	163
	$\Sigma X=20$	$\Sigma Y=31$	$\Sigma X^2=110$	$\Sigma Y^2=247$	$\Sigma XY=163$

$$r = \frac{5(163)-(20)(31)}{\sqrt{5(110)-(20)^2}\sqrt{5(247)-(31)^2}} = 0{,}9618$$

TESTE DE HIPÓTESE PARA O COEFICIENTE LINEAR

Para o nosso exemplo queremos testar se existe ou não correlação linear entre X = Doses de calcário (t ha-1) e Y = produtividade de milho (t ha-1).
Vamos verificar se existe relacionamento linear entre as duas variáveis ao nível de 5% de significância.

a) As hipóteses a serem testadas são: H_0: $\rho = 0$ (Não existe relacionamento linear na população) H_1: $\rho \neq 0$ (Existe relacionamento linear na população) (teste bilateral)

b) Nível de significância do teste, ou erro tipo I ($\alpha = 5\%$)

c) Teste estatístico

$$t_{calc} = \frac{r}{\sqrt{\frac{1-r^2}{n-2}}} \rightarrow t_{calc} = \frac{0{,}9618}{\sqrt{\frac{1-0{,}9618^2}{5-2}}} = 6{,}09$$ Comparar com o valor de $t_{tab\ com\ n\text{-}2\ graus\ de\ liberdade}$ (Tabela 2)

d) Comparar com o valor de $t_{tab\ 5\%\ bilateral}$ ou $t_{tab\ 2{,}5\%\ unilateral\ com\ (5\text{-}2) = 3\ gl}$ ➔ $t_{tab} = 3{,}182$

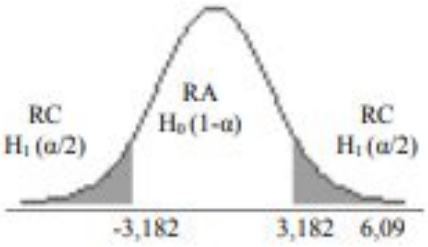

Lado esquerdo ➔ de menos infinito até -3,182 acumula uma área de 2,5% (Tabela 2).
Lado direito ➔ de 3,182 até mais infinito acumula uma área de 2,5% (Tabela 2).

e) Conclusão: tcalc (6,09) está dentro de H_1, logo rejeitamos H_0 e podemos afirmar, ao nível de 5% de significância, ou 5% de probabilidade de erro, que existe relacionamento linear na população, ou seja, o aumento da dose de calcário ocasiona um aumento na produtividade de milho. Ou ainda a correlação linear entre essas duas variáveis é significativa.

Dado que há fortes evidências de que as duas variáveis possuem um relacionamento linear pode-se então ajustar uma linha de regressão entre elas.

OBSERVAÇÕES:

- Correlação não é o mesmo que causa e efeito.
- Duas variáveis podem estar altamente correlacionadas e, no entanto, não haver relação de causa e efeito entre elas.
- Se duas variáveis estiverem amarradas por uma relação de causa e efeito elas estarão, obrigatoriamente, correlacionadas.
- O estudo de correlação pressupõe que as variáveis X e Y tenham uma distribuição normal.
- A palavra simples que compõe o nome correlação linear simples, indica que estão envolvidas no cálculo somente duas variáveis.
- O coeficiente de correlação linear de Pearson mede a correlação em estatística paramétrica.

Exemplo

Um gerente de marketing conduziu um estudo para determinar se há uma relação entre o dinheiro gasto com propaganda e as vendas da empresa. Os dados são mostrados na tabela ao lado.

Gastos com propaganda (1.000 de $), x	Vendas da empresa (1.000 de $), y
2,4	225
1,6	184
2,0	220
2,6	240
1,4	180
1,6	184
2,0	186
2,2	215

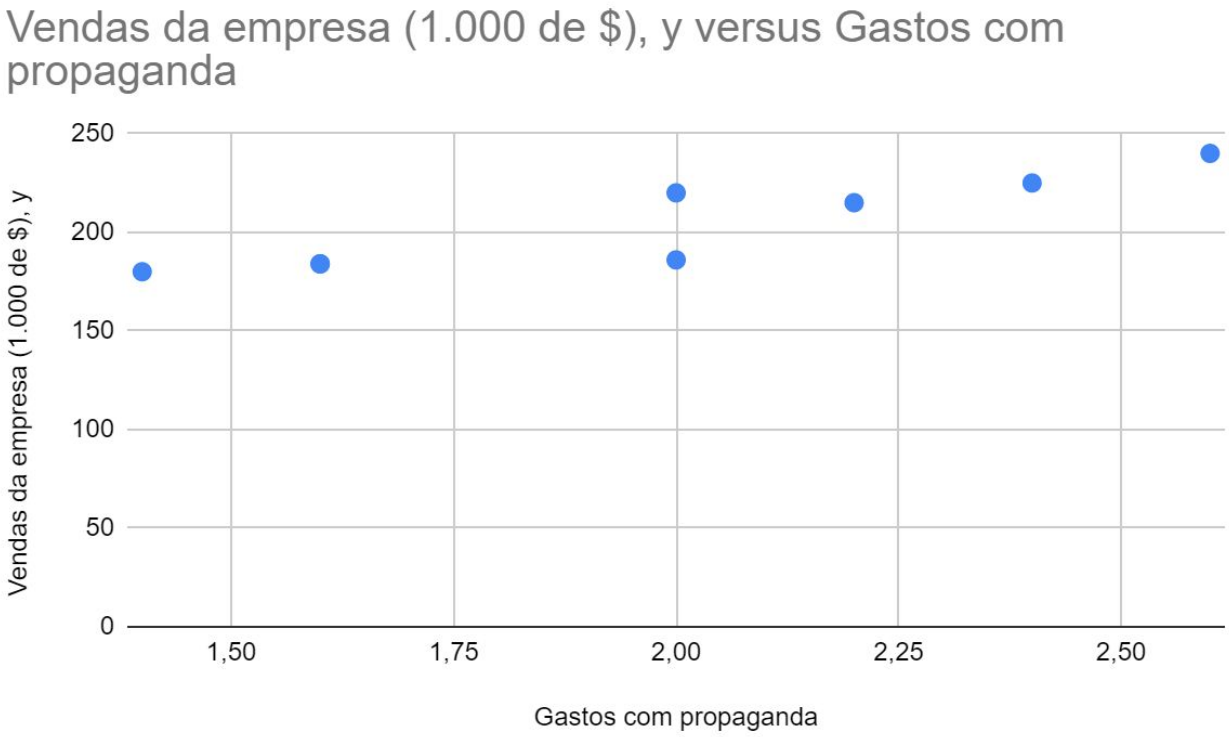

Parece haver uma correlação linear positiva entre as variáveis.

Lendo da esquerda para direita, conforme os gastos com com propaganda aumenta, as vendas tendem a aumentar.

A correlação é calculada usando uma planilha eletrônica (excel)

Correlação = 0,9129052847

Comparando com os valores dados anteriormente, isso representa uma correlação forte.

Para o teste de hipótese existe uma tabela onde relaciona o ρ e o número de elementos.

Tabela A-6	Valores Críticos do Coeficiente de Correlação de Pearson *r*						
n	$\alpha = 0{,}10$	$\alpha = 0{,}05$	$\alpha = 0{,}025$	$\alpha = 0{,}02$	$\alpha = 0{,}01$	$\alpha = 0{,}005$	$\alpha = 0{,}001$
4	0,900	0,950	0,975	0,980	0,990	0,995	0,999
5	0,805	0,878	0,924	0,934	0,959	0,974	0,991
6	0,729	0,811	0,868	0,882	0,917	0,942	0,974
7	0,669	0,754	0,817	0,833	0,875	0,906	0,951
8	0,621	0,707	0,771	0,789	0,834	0,870	0,925
9	0,582	0,666	0,732	0,750	0,798	0,836	0,898
10	0,549	0,632	0,697	0,715	0,765	0,805	0,872
11	0,521	0,602	0,667	0,685	0,735	0,776	0,847
12	0,497	0,576	0,640	0,658	0,708	0,750	0,823
13	0,476	0,553	0,616	0,634	0,684	0,726	0,801
14	0,458	0,532	0,594	0,612	0,661	0,703	0,780
15	0,441	0,514	0,575	0,592	0,641	0,683	0,760
16	0,426	0,497	0,557	0,574	0,623	0,664	0,742
17	0,412	0,482	0,541	0,558	0,606	0,647	0,725
18	0,400	0,468	0,526	0,543	0,590	0,631	0,708
19	0,389	0,456	0,512	0,529	0,575	0,616	0,693
20	0,378	0,444	0,499	0,516	0,561	0,602	0,679
25	0,337	0,396	0,447	0,462	0,505	0,543	0,618
30	0,306	0,361	0,409	0,423	0,463	0,499	0,570
35	0,283	0,334	0,378	0,392	0,430	0,464	0,532
40	0,264	0,312	0,354	0,367	0,403	0,435	0,501
45	0,248	0,294	0,334	0,346	0,380	0,411	0,474
50	0,235	0,279	0,317	0,328	0,361	0,391	0,451
60	0,214	0,254	0,289	0,300	0,330	0,358	0,414
70	0,198	0,235	0,268	0,278	0,306	0,332	0,385
80	0,185	0,220	0,251	0,260	0,286	0,311	0,361
90	0,174	0,207	0,236	0,245	0,270	0,293	0,341
100	0,165	0,197	0,224	0,232	0,256	0,279	0,324

Nota: Para testar H_0: $\rho = 0$ versus H_1: $\rho \neq 0$.

Rejeite H_0 se o valor absoluto de *r* for maior que o valor crítico na tabela.

Exemplo

Um estudante de enfermagem conduz um estudo para determinar se há uma correlação linear entre os pesos dos indivíduos (em libras) e o consumo diário de água (em onças). Os dados são mostrados na tabela a seguir. Organize os dados no diagrama de dispersão e descreva o tipo de correlação.

Peso, x	142	201	119	102	141	124	220	154
Água, y	54	86	32	50	64	82	39	21

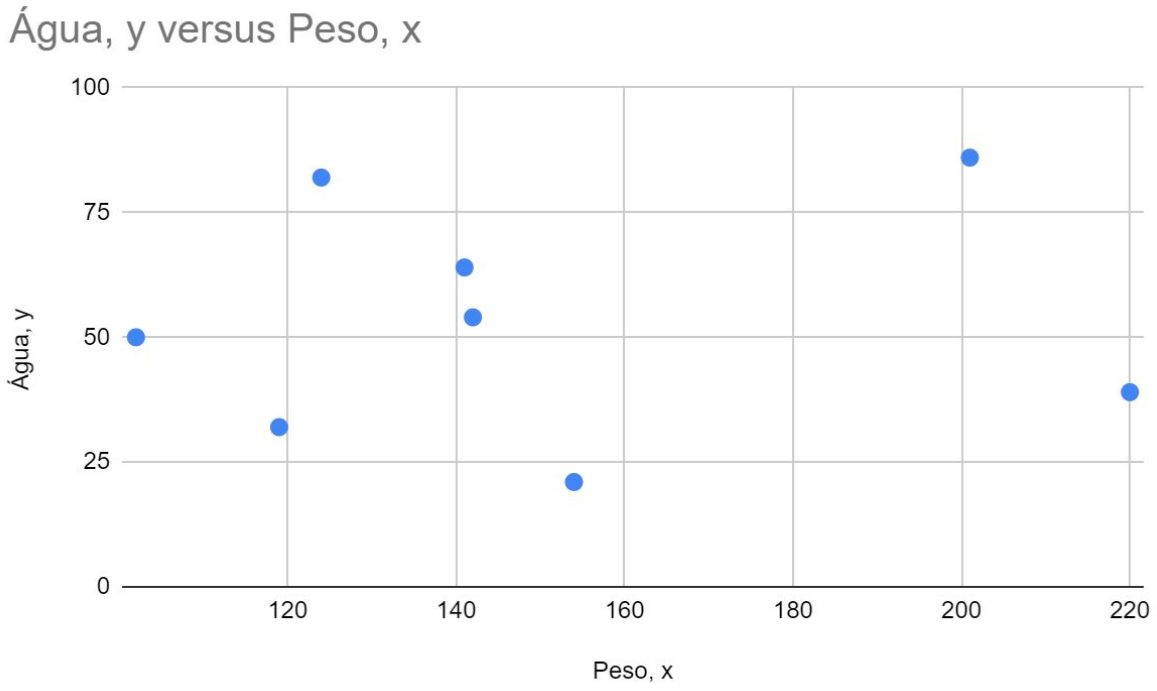

Parece não haver correlação linear entre as variáveis.

O peso de uma pessoa não parece estar relacionado com a quantidade de água que ela consome.

A correlação é calculada usando uma planilha eletrônica (excel)

Correlação = 0,07725035531

Comparando com os valores dados anteriormente, isso representa uma correlação nula.