Estatística e Probabilidade

Regressão Linear

Linhas de regressão

Após verificar se a correlação linear entre duas variáveis é significante,

O próximo passo é determinar a equação da linha que melhor modela os dados.

Essa linha é chamada de linha de regressão e

Sua equação pode ser usada para prever os valores de y para um conjunto de valor de x.

Embora muitas linhas possam ser desenhadas através de um conjunto de pontos, uma linha de regressão é determinada por um critério específico.

Exemplo do ponto na linha de ajuste (previsto) e o observado

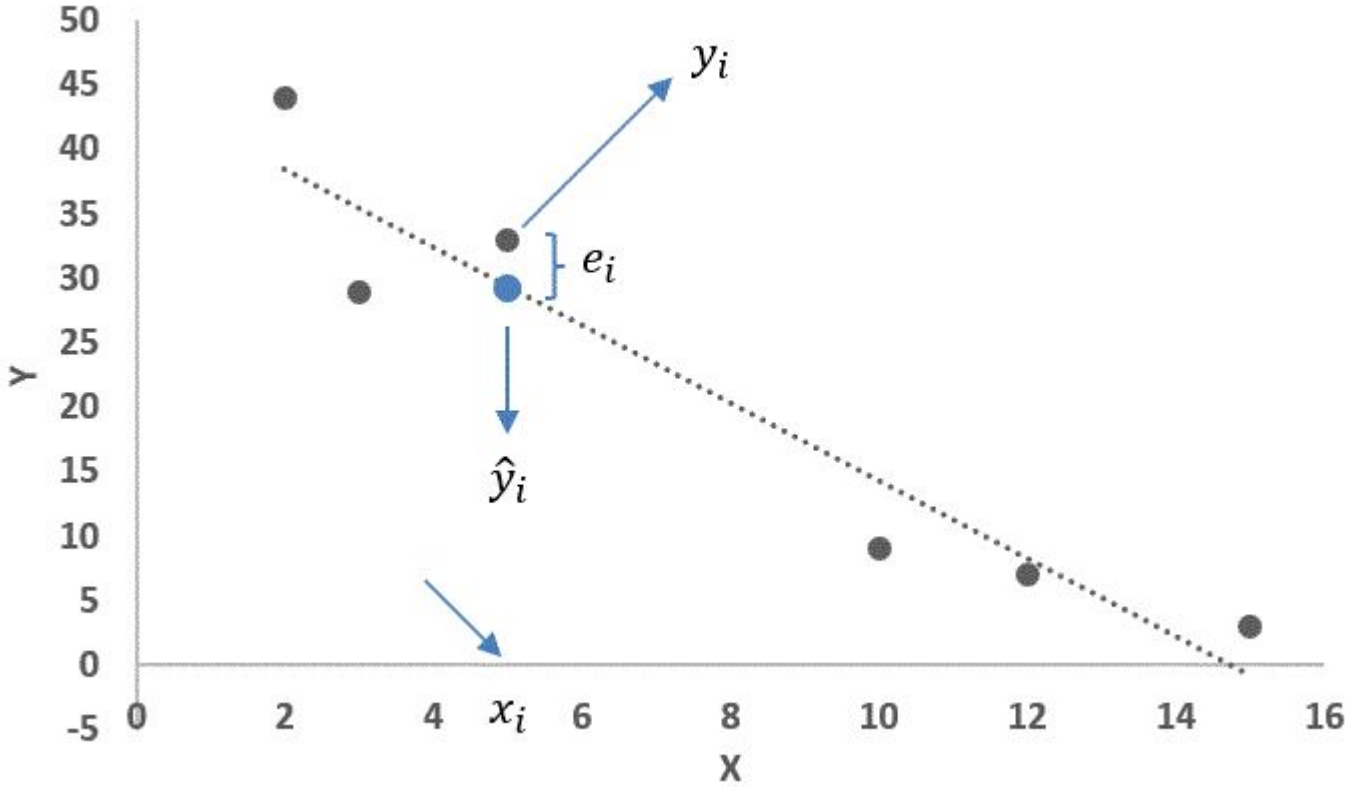

Considere o diagrama de dispersão e a linha mostrados a seguir.

Para cada ponto dado, e_i , representa a diferença entre o valor y observado e o valor y previsto para um dado valor x na linha.

Essas diferenças chamados são **resíduos** e podem ser positivas, negativas ou zero.

Quando o ponto está acima da linha, e_i é positivo. Quando está abaixo da linha, e_i é negativo. Se o valor observado é igual ao valor y previsto, $e_i = 0$.

De todas as linhas possíveis que podem ser desenhadas através de um conjunto de dados, a linha de regressão é a linha para a qual a soma dos quadrados de todos os resíduos:

$$\sum e_i^2$$ é o mínimo.

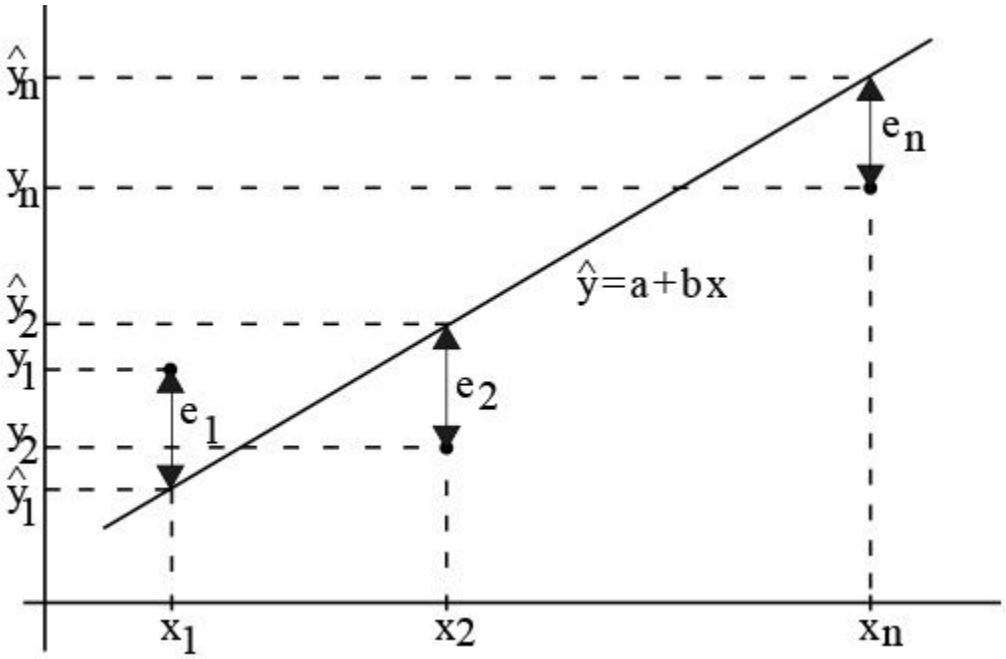
$\hat{y}_n$
y_n
$\hat{y}_2$
y_1
y_2
$\hat{y}_1$
e_n
$\hat{y}=a+bx$
e_2
e_1
x_1
x_2
x_n

Definição

Uma **linha de regressão**, também chamada de **linha de melhor ajuste**, é a linha para a qual a soma dos quadrados dos resíduos é um mínimo.

A equação de uma reta de regressão

A equação de uma reta de regressão para uma variável independente x e uma variável dependente y é:

$$\hat{y} = mx + b$$

onde $\hat{y}$ é o valor y previsto para um dado valor x. A inclinação m e a interseção y b são dadas por

$$m = \frac{n\sum xy - \left(\sum x\right)\left(\sum y\right)}{n\sum x^2 - \left(\sum x\right)^2} \quad \text{e} \quad b = \bar{y} - m\bar{x} = \frac{\Sigma y}{n} - m\frac{\Sigma x}{n}$$

onde $\bar{y}$ é a média dos valores y no conjunto de dados e $\bar{x}$ é a média dos valores x. A linha de regressão sempre passa pelo ponto $(\bar{x}, \bar{y})$

Exemplo 1

Encontre a equação da reta de regressão para os gastos com propaganda e dados sobre vendas da empresa da tabela ao lado.

Gastos com propaganda (1.000 de $), x	Vendas da empresa (1.000 de $), y
2,4	225
1,6	184
2,0	220
2,6	240
1,4	180
1,6	184
2,0	186
2,2	215

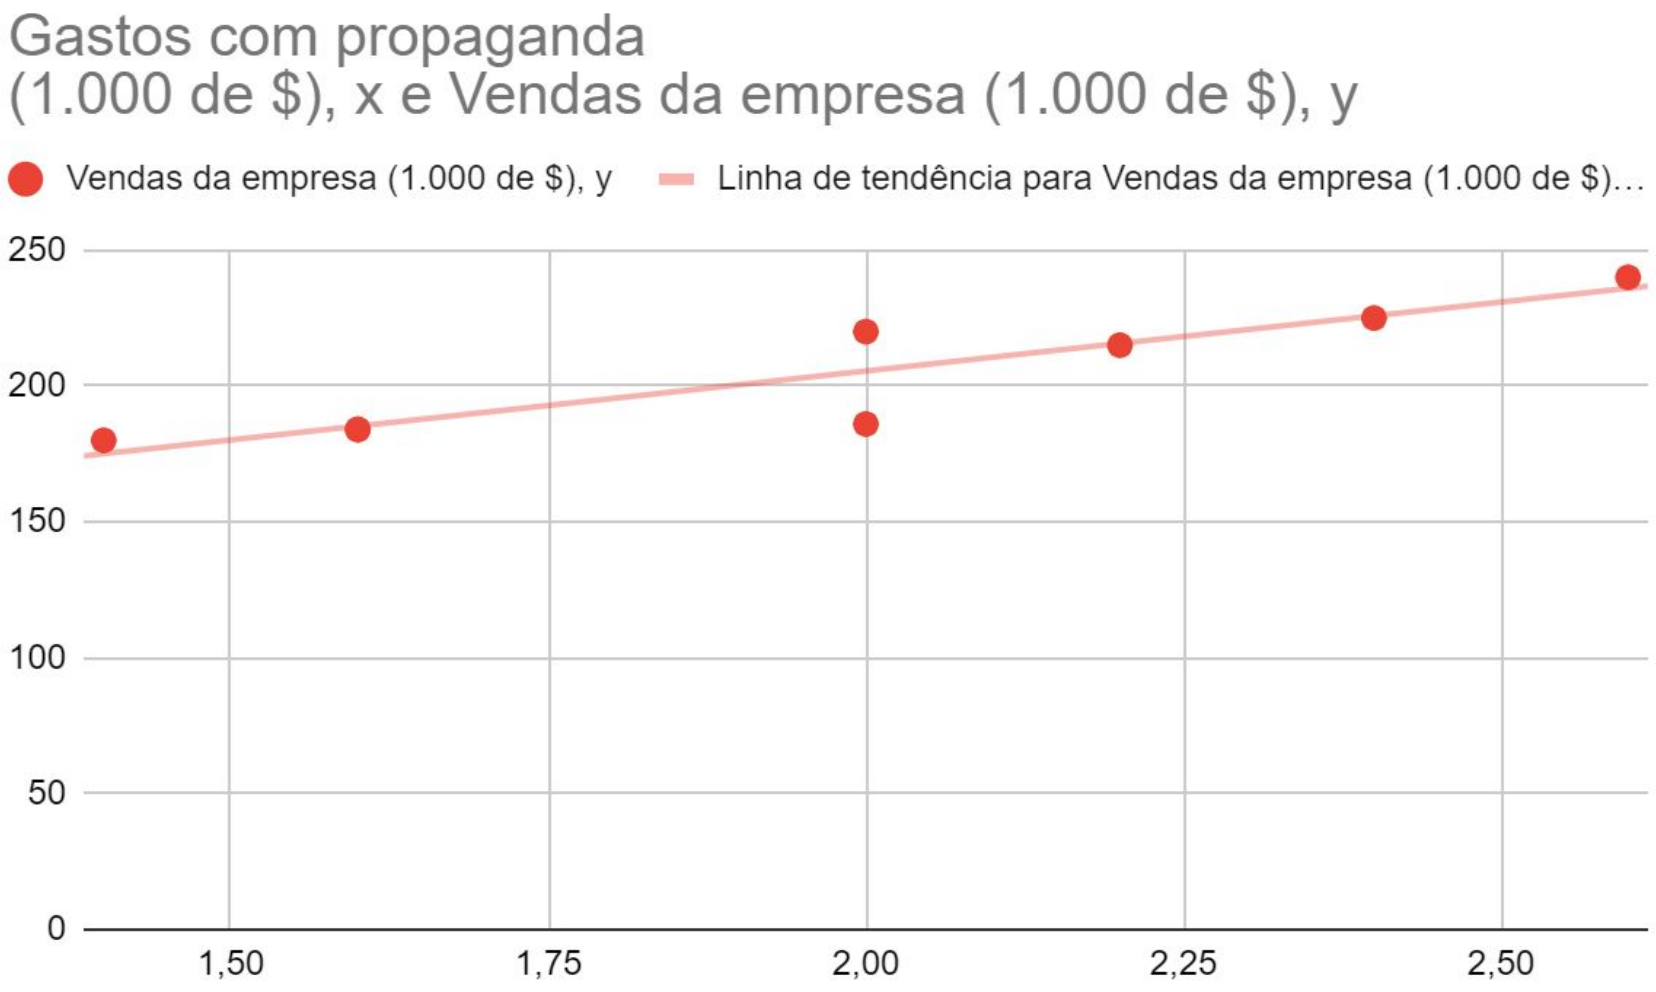
Gastos com propaganda
(1.000 de $), x e Vendas da empresa (1.000 de $), y
Vendas da empresa (1.000 de $), y
Linha de tendência para Vendas da empresa (1.000 de $)…
250
200
150
100
50
0
1,50
1,75
2,00
2,25
2,50

Exemplo 2

Use uma ferramenta de tecnologia para encontrar a equação da linha de regressão para os dados do Old Faithful da tabela ao lado.

Duração, x	Tempo, y
1,8	56
1,82	58
1,9	62
1,93	56
1,98	57
2,05	57
2,13	60
2,3	57
2,37	61
2,82	73
3,13	76
3,27	77
3,65	77

Duração, x	Tempo, y
3,78	79
3,83	85
3,88	80
4,1	89
4,27	90
4,3	89
4,43	89
4,47	86
4,53	89
4,55	86
4,6	92
4,63	91

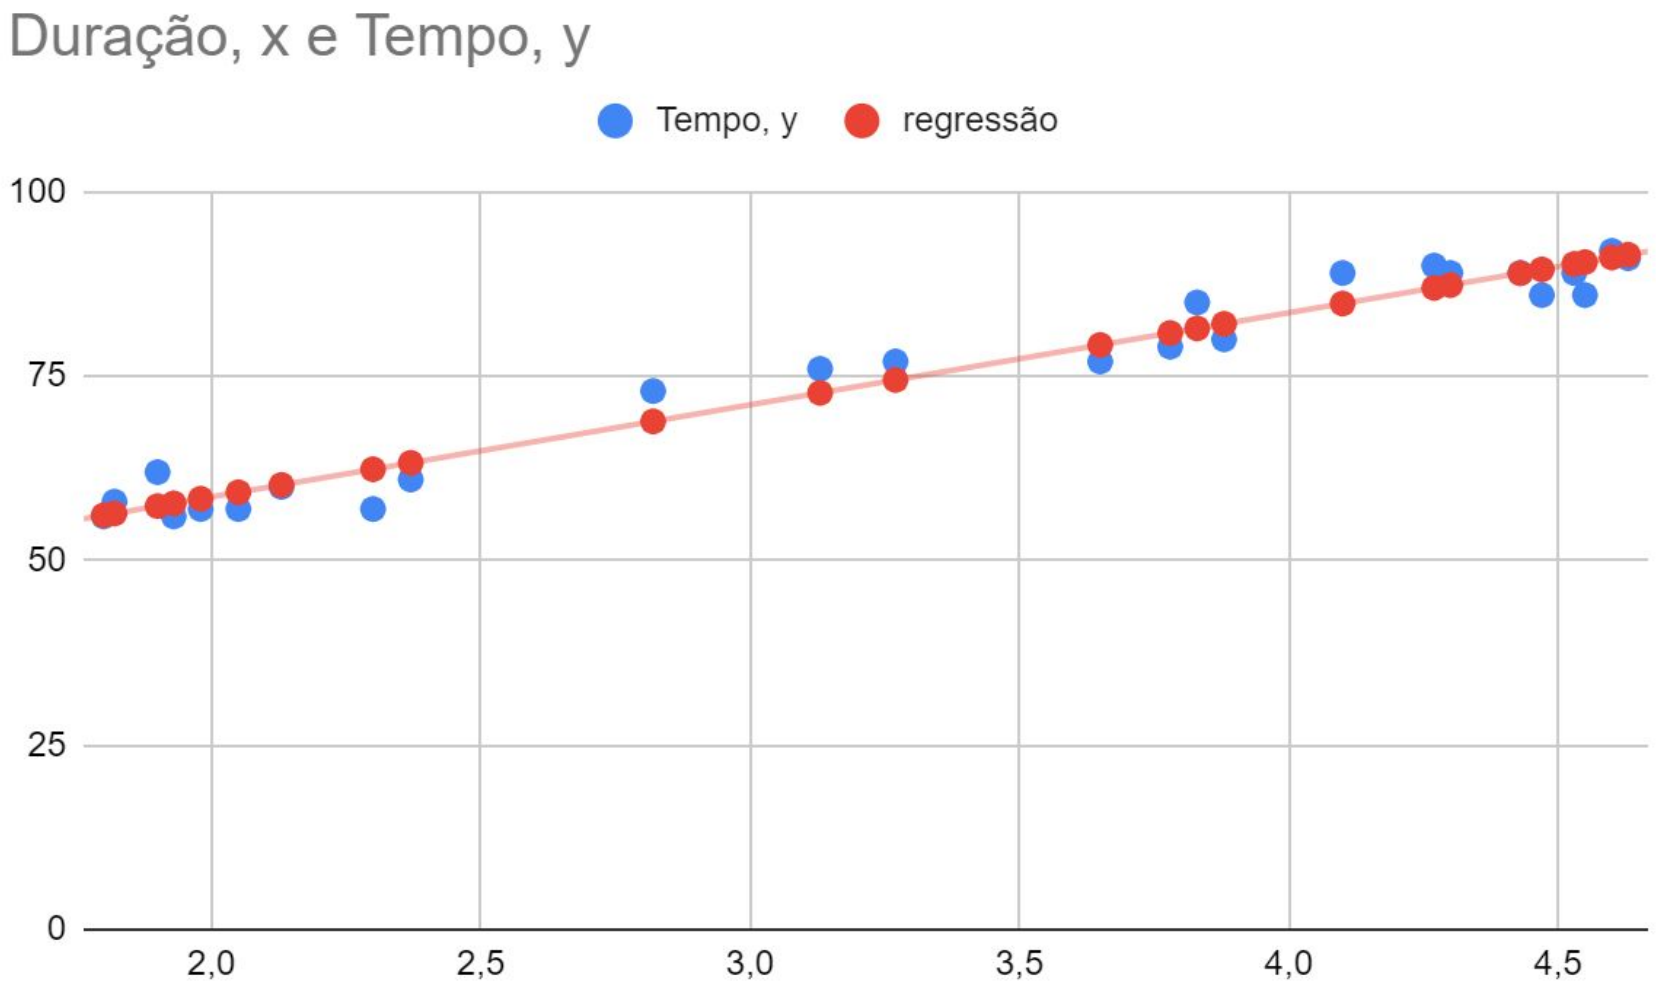
Duração, x e Tempo, y
Tempo, y
regressão
100
75
50
25
0
2,0
2,5
3,0
3,5
4,0
4,5

Exemplo 3

A equação de regressão para os dados sobre gastos com propaganda (em milhares de dólares) e vendas da empresa (em milhares de dólares) é:

$$\hat{y} = 50,729x + 104,061$$

Use essa equação para prever as vendas esperadas da empresa para os seguintes gastos com propaganda.

1. 1,5 mil dólares
2. 1,8 mil dólares
3. 2,5 mil dólares

Cálculo da tendência a partir da equação de regressão

m	50,72874494	
b	104,0607287	
	$\hat{y} = 50,729x + 104,061$	
1,5		180,1538462
1,8		195,3724696
2,5		230,8825911

Exemplo 4

A equação de regressão para os dados do Old Faithful é:

$$\hat{y} = 12,48x + 33,68$$

Use isso para prever o tempo até que a próxima erupção para cada uma das erupções a seguir:

1. 2 minutos
2. 3,32 minutos

Cálculo da tendência a partir da equação de regressão

m	12,48094391	
b	33,68290034	
	$\hat{y} = 12,48x + 33,68$	
2		58,64478816
2,32		62,63869021